



MULTIMEDIA FORENSICS

Adversarial Machine Learning

Francesco Guarnera

francesco.guarnera@unict.it
www.dmi.unict.it/fguarnera

Luca Guarnera

luca.guarnera@unict.it
www.dmi.unict.it/lguarnera



Uni
ct

MATEMATICA
E INFORMATICA

Il successo del Machine/Deep Learning



Autonomous Driving



Healthcare



Smart City



Malware Classification




Fraud Detection



Biometrics Recognition

Siamo realmente pronti?



L'adversarial learning rappresenta una serie di tecniche che mirano a minare le prestazioni dell'apprendimento automatico, attraverso la definizione di input speciali (esempi adversarial) che un utente malintenzionato ha intenzionalmente progettato per causare un errore nel modello.



Adversarial Learning

La precisione della classificazione di GoogLeNet su MNIST sotto attacchi avversari scende dal 98% al 18% (ProjGrad) o all'1% (DeepFool)


Attack	Lenet				
Noise	Dataset	Acc@1 w/	Acc@5 w/	Acc@1 w/o	Acc@5 w/o
	MNIST	0.984	1.0	0.9858	1.0
	ILSVRC2012	NA	NA	NA	NA
Semantic	Dataset	Acc@1 w/	Acc@5 w/	Acc@1 w/o	Acc@5 w/o
	MNIST	0.233	0.645	0.986	1.0
	ILSVRC2012	NA	NA	NA	NA
Fast Gradient Sign Method	Dataset	Acc@1 w/	Acc@5 w/	Acc@1 w/o	Acc@5 w/o
	MNIST	0.509	0.993	0.986	1.0
	ILSVRC2012	NA	NA	NA	NA
Projected Gradient Descent	Dataset	Acc@1 w/	Acc@5 w/	Acc@1 w/o	Acc@5 w/o
	MNIST	0.187	0.982	0.986	1.0
	ILSVRC2012	NA	NA	NA	NA
DeepFool	Dataset	Acc@1 w/	Acc@5 w/	Acc@1 w/o	Acc@5 w/o
	MNIST	0.012	1.0	0.9858	1.0
	ILSVRC2012	NA	NA	NA	NA

Adversarial Learning

Esempi



Differenza



Adversarial Learning

Altro esempio: un'immagine perturbata di un panda viene erroneamente classificata come un gibbon. L'immagine all'occhio umano sembra indistinguibile dall'immagine originale

Original image



Classified as **panda**
57.7% confidence



Small adversarial noise



Adversarial image



Classified as **gibbon**
99.3% confidence



Gibbon


Adversarial Learning

Altro esempio (pericoloso): uno studio recente ha manipolato un segnale di stop facendo sì che il modello DL di un'auto a guida autonoma lo classificasse come segnale di limite di velocità 45



Adversarial Learning

Esempio detection (YOLOv2): adversarial patch costruita ad hoc per evitare le detection



***C'è un terno in
corridoio....***




Adversarial Learning

L'AML è un campo di ricerca che si trova all'intersezione tra ML e sicurezza informatica. Ad esempio, rilevamento delle intrusioni di rete, filtraggio dello spam, classificazione del malware, autenticazione biometrica (rilevamento facciale).


Gli algoritmi ML nelle applicazioni del mondo reale si concentrano principalmente su una maggiore precisione.

Solo, poche tecniche e decisioni di progettazione si concentrano sul mantenimento della sicurezza e della robustezza dei modelli di ML.

Gli approcci di ML/DL presuppongono che i dati di training e quelli di test appartengano alla stessa distribuzione.



Adversarial Learning



Ma in realtà, le distribuzioni su cui utilizziamo il ML/DL non sono quelle su cui lo addestriamo!

Adversarial Learning

Le DNN sono potenti perché i loro numerosi livelli consentono di rilevare caratteristiche diverse di un input quando tentano di classificarlo.


Ma questo significa anche che un cambiamento molto piccolo nell'input può ribaltarlo in quello che il modello considera uno stato apparentemente diverso.

Le tipologie di perturbazione applicati negli attacchi avversari dipendono **dal tipo di dati target e dall'effetto desiderato.**

Adversarial Learning

La fase di training definisce un modello di confine decisionale (linea rossa) che si avvicina solamente al confine decisionale reale (linea blu).

- Il confine decisionale reale diventa più complesso man mano che lo spazio delle caratteristiche diventa più ampio.
- Nelle DNN profonde lo spazio delle caratteristiche è una combinazione di numerosissime funzioni non lineari.



Costruzione di modelli «adversarial»

L'addestramento di un classificatore viene spesso formulato come la ricerca dei parametri del modello θ che minimizzano una funzione di perdita empirica per un dato insieme di campioni $x_1, \dots, x_n$

$$\min_{\theta} \sum_x \text{loss}(x, \theta)$$

Per causare una classificazione errata per un modello fisso θ e un input “benigno” x , un approccio naturale consiste nel trovare una perturbazione limitata δ tale che la perdita su $x+\delta$ sia la più grande possibile:


$$\max_{\delta} \text{loss}(x + \delta, \theta)$$

Adversarial Learning


Nonostante i punti grigi/rossi siano alla stessa distanza da x nello spazio di input, l'esempio contraddittorio (rosso) è molto più lontano nello spazio delle features.

Perturbazioni casuali nello spazio di input determinano solo uno spostamento molto piccolo nello spazio di input, ma possono generare un grande spostamento nello spazio profondo.

Input space






Deep feature space



Adversarial Learning

Szegedy et al. (2013) ha scoperto per la prima volta che le DNN ben funzionanti sono suscettibili agli attacchi avversari




Tutte le immagini sono state classificate come «struzzo»



original

difference

adversarial example



original



difference

adversarial example

Adversarial Learning

Un altro lavoro del 2015 (Nguyen et. al) ha mostrato come inoltre è possibile generare immagini classificabili per le DNN ma totalmente senza significato

99.99%
confidence




Adversarial Learning

1

State-of-the-art DNNs can recognize real images with high confidence


2

But DNNs are also easily fooled: images can be produced that are unrecognizable to humans, but DNNs believe with 99.99% certainty are natural objects




Altri esempi

***2020: Occhiali
che ingannano
una DNN di Face
Recognition***




Adversarial Learning

Audio: identico procedimento



Adversarial Learning

Adversarial attacks contro il Sistema di speech recognition




Adversarial Learning

Differenze con i deepfake?

Nell'**Adversarial Machine Learning** l'obiettivo del contenuto generato è ingannare una macchina (cioè un algoritmo) e non un essere umano.

Samples created by machines
to fool...




Examples:

- ...**humans**: entertainment, impersonation, art fraud.
- ...**machines**: hiding a stop sign, evading face recog.
- ...**both**: tampering medical scans, malware evasion.

Adversarial Learning

Il piano di attacco può essere definito rispetto alla pipeline di elaborazione dei dati.




Un attaccante può tentare di manipolare la raccolta o l'elaborazione dei dati per corrompere il modello di destinazione, manomettendo così l'output originale.

Adversarial Learning

Data poisoning (avvelenamento): Attacco alla fase di training


- Gli attaccanti disturbano il training set per ingannare il modello
 - ✓ Inserimento input dannosi nel training set
 - ✓ Modifica/elimina delle istanze di input nel training set
 - ✓ Modifica delle etichette di input di formazione
- Gli attaccanti tentano di influenzare o corrompere il modello ML o l'algoritmo ML stesso



Adversarial Learning

Evasion attack: Attacco alla fase di test

- Gli attaccanti non disturbano il modello ma capiscono come perturbare l'output
- Rappresenta l'attacco più comune




Evasion attack

- White-box attack
 - ✓ Gli attaccanti hanno piena conoscenza del modello ML, cioè accesso a parametri, iperparametri, gradienti, architettura, ecc.
- Black-box attack
 - ✓ Gli attaccanti non hanno accesso ai parametri, ai gradienti e all'architettura del modello
 - ✓ Hanno al massimo una certa conoscenza dell'algoritmo ML utilizzato (ad esempio, gli aggressori potrebbero sapere che per la classificazione viene utilizzato un modello ResNet50, ma non hanno accesso ai parametri del modello, quindi interrogano il modello per ottenere informazioni)

Adversarial Learning


Adversarial Capabilities

Data Poisoning Attack



Weaker

Evasion Attack



Stronger 💀

Adversarial Learning

Ciascuno degli attacchi precedenti può inoltre essere:

- **Attacco non mirato**
 - ✓ L'obiettivo è indurre in errore il classificatore a prevedere eventuali etichette diverse dall'etichetta di verità fondamentale
 - ✓ La maggior parte dei lavori esistenti riguarda questo obiettivo
- **Attacco mirato**
 - ✓ L'obiettivo è indurre in errore il classificatore a prevedere un'etichetta precisa
 - ✓ Più complicato da effettuare

Adversarial Learning


1. From: spammer@example.com
Cheap mortgage now!!!

Feature Weights



2. cheap = 1.0
mortgage = 1.5

3. Total score = 2.5 > 1.0 (threshold)

Spam




Adversarial Learning



Adversarial Learning

Evasion attack


Creazione esempio: $X^* = X + \delta X$ aggiungendo un rumore δX , così $F(X^*) = Y^*$ dove Y^* è il target desiderato.



Adversarial Learning

Evasion attack

L'attaccante sfrutta quindi la conoscenza delle informazioni sensibili per selezionare un item in grado di ottenere l'output errato desiderato.



$$X_* = X + \arg \min_{\delta X} \{ \|\delta X\| : F(X + \delta X) \neq F(X) \}$$

Poisoning attack


Un processo di apprendimento mette a punto i parametri θ dell'ipotesi $h_{\theta}(x)$ analizzando un training set. Ciò rende il set di allenamento suscettibile alla manipolazione da parte degli attaccanti.

L'attacco di Poisoning altera il training set inserendo, modificando o eliminando punti mantenendo l'intenzione di modificare i confini decisionali del modello preso di mira.

- Manipolazione delle etichette
- Manipolazione dell'input


Adversarial Learning

Poisoning attack: manipolazione etichette



Adversarial Learning

Poisoning attack: manipolazione input




Tipologie attacchi adversarial

- Noise attack
- Semantic attack
- Fast gradient sign method (FGSM) attack
- Basic iterative method (BIM) attack
- Projected gradient descent (PGD) attack
- DeepFool attack

Adversarial Learning


Noise attack

- La forma più semplice di attacco
- Il rumore è una disposizione casuale di pixel che non contengono informazioni
- Rappresenta un attacco evasivo a scatola nera non mirato




Prediction: gorilla

+



=




Prediction: fountain

Adversarial Learning

Semantic attack

- Usa immagini negative
 - ✓ Invertire tutte le intensità dei pixel
 - ✓ Rappresenta un attacco evasivo a scatola nera non mirato

Originale: gorilla



Negativo: weimaraner



Adversarial Learning

Fast gradient sign method (FGSM) attack

Un'immagine contraddittoria x_{adv} viene creata aggiungendo rumore di perturbazione a un'immagine x

$$x_{adv} = x + \epsilon \cdot \text{sign}(\nabla_x \mathcal{L}(h(x, w), y))$$

con immagine di input x , funzione costo $\mathcal{L}$, NN con modello h , pesi NN (parametri) w , gradiente ∇ , magnitudo del rumore ϵ

- Il rumore di perturbazione viene calcolato come il gradiente della funzione loss $\mathcal{L}$ rispetto all'immagine di input x per l'etichetta di classe vera y
- Ciò aumenta la loss per la vera classe $y \rightarrow$ il modello classifica erroneamente l'immagine x_{adv}

$$\text{sgn}(x) := \begin{cases} -1 & \text{if } x < 0, \\ 0 & \text{if } x = 0, \\ 1 & \text{if } x > 0. \end{cases}$$

Adversarial Learning

Fast gradient sign method (FGSM) attack è un attacco evasivo non mirato a scatola bianca

 x

“panda”

57.7% confidence

+ .007 ×

 $\text{sign}(\nabla_x J(\theta, x, y))$

“nematode”

8.2% confidence

=


 $x + \epsilon \text{sign}(\nabla_x J(\theta, x, y))$

“gibbon”

99.3 % confidence

Adversarial Learning


- L'addestramento delle NN si basa sull'algoritmo di discesa del gradiente
 - I valori dei parametri di rete (pesi) w vengono modificati iterativamente fino al raggiungimento del minimo della funzione di perdita
 - I gradienti della funzione di perdita rispetto ai parametri del modello ($\partial l / \partial w$) danno la direzione e l'entità per l'aggiornamento dei parametri
 - Il passo di ogni aggiornamento è il tasso di apprendimento α



Adversarial Learning

Il segno e l'entità del gradiente danno la direzione e la pendenza della discesa più ripida

- Immagine a sinistra: segno + e – del gradiente
 - Immagine a destra: pendenza piccola, adeguata e grande dell'aggiornamento del peso, in base all'entità del gradiente
 - Immagine centrale: α piccolo e grande (velocità di apprendimento) Per ridurre al minimo la funzione di perdita, i pesi w vengono modificati nella direzione opposta del gradiente, ovvero $w = w - \alpha$
- $\partial loss / \partial w$



Adversarial Learning

Basic iterative method (BIM) attack

è una variante di FGSM, aggiunge ripetutamente rumore all'immagine x in più iterazioni, al fine di causare una classificazione errata

Un'immagine contraddittoria x_{adv} viene creata aggiungendo rumore di perturbazione a un'immagine x

$$x_{adv}^t = x^{t-1} + \epsilon \cdot \text{sign}(\nabla_x \mathcal{L}(h(x^{t-1}), y))$$

con immagine di input x , funzione costo $\mathcal{L}$, NN con modello h , pesi NN (parametri) w , gradiente ∇ , magnitudo del rumore ϵ

Projected Gradient Descent (PGD) attack

è una variante di FGSM e di BIM, dove dopo ogni fase di perturbazione, l'esempio contraddittorio viene proiettato nuovamente all'interno dell'immagine tramite la funzione Π_ϵ

Un'immagine contraddittoria x_{adv} viene creata aggiungendo rumore di perturbazione a un'immagine x

$$x_{adv}^t = \Pi_\epsilon(x^{t-1} + \epsilon \cdot \text{sign}(\nabla_x \mathcal{L}(h(x^{t-1}), y)))$$

(Diversamente dal BIM) PGD utilizza l'inizializzazione casuale per x , aggiungendo rumore casuale da una distribuzione uniforme con valori nell'intervallo $(-\epsilon, \epsilon)$

Adversarial Learning

Gli approcci basati su gradiente (FGSM, BIM, PGD) possono anche essere progettati come attacchi white-box mirati

In questo caso, il rumore di perturbazione aggiunto deve mirare a ridurre al minimo la funzione di perdita dell'immagine rispetto ad un'etichetta di classe specifica



Prediction: **hippopotamus**



Prediction: **maraca**



Maraca

Adversarial Learning

Nel caso del Projected Gradient Descent (PGD), data la classe target T la formula cambia da

$$x_{adv}^t = \Pi_{\epsilon}(x^{t-1} + \epsilon \cdot \text{sign}(\nabla_x \mathcal{L}(h(x^{t-1}), y)))$$

$$x_{adv}^t = \Pi_{\epsilon}(x^{t-1} + \epsilon \cdot \text{sign}(\nabla_x \mathcal{L}(h(x^{t-1}), T)))$$


Adversarial Learning

DeepFool attack

è un attacco white-box non mirato

Classifica erroneamente l'immagine con la minima quantità di perturbazione possibile

Non vi è alcun cambiamento visibile all'occhio umano tra le due immagini




Adversarial Learning

Sia DeepFool che FGSM perturbano l'immagine in modo che venga classificata come tartaruga

DeepFool porta a una perturbazione minore

DeepFool





FGSM




Adversarial Learning

In una classificazione binaria, **DeepFool** perturba X in modo da farle attraversare l'iperpiano



Adversarial Learning

In una classificazione multiclasse esistono più iperpiani. Deepfool trova l'iperpiano più vicino (attacco non mirato) da «attraversare»



Adversarial Learning

Le immagini perturbate possono causare il fallimento di qualsiasi algoritmo di ML, tuttavia, possono essere utilizzati per costruire modelli più accurati e robusti

AML è un gioco a due giocatori: gli attaccanti mirano a produrre forti esempi contraddittori che eludono un modello con elevata confidenza richiedendo solo una piccola perturbazione.

I difensori mirano a produrre modelli che siano robusti rispetto agli esempi contraddittori



MULTIMEDIA FORENSICS

Grazie

Francesco Guarnera

francesco.guarnera@unict.it
www.dmi.unict.it/fguarnera

Luca Guarnera

luca.guarnera@unict.it
www.dmi.unict.it/lguarnera



Uni
ct

MATEMATICA
E INFORMATICA