



Architectures for Deepfake Creation

Prof. Francesco Guarnera
&
Prof. Luca Guarnera






Uni
ct

MATEMATICA
E INFORMATICA

1

Why it is important to understand the deepfake creation pipeline?



Luca Guarnera luca.guarnera@unict.it

Architectures for Deepfake Creation

2

Overview

- Facial manipulation group
- Introduction to Autoencoder
- Introduction to Generative Adversarial Networks
- Introduction to Diffusion Models
- Deepfake Creation



Luca Guarnera luca.guarnera@unict.it

Architectures for Deepfake Creation

3



Facial Manipulation Group

4

Facial manipulation group

Entire Face Synthesis



This manipulation creates entire non-existent face images, usually through powerful GAN, e.g. StyleGAN.

Attribute Manipulation



This manipulation, also known as **face editing** or **face retouching**, consists of modifying some attributes of the face such as the hair color, the gender, the age, adding glasses, etc.

Identity Swap



This manipulation consists of replacing the face of one person in a video with the face of another person.

Expression Swap



This manipulation, also known as **face reenactment**, consists of modifying the facial expression of the person



Luca Guarnera luca.guarnera@unict.it

Architectures for Deepfake Creation

5

Nomenclature: Face Swapping

Swapping faces means **transferring a face** from a source photo onto a face appearing in a target photo, **attempting to generate realistic, unedited looking results**



Nirkin, Y., Masi, I., Tuan, A. T., Hassner, T., & Medioni, G. (2018, May). **On face segmentation, face swapping, and face perception**. In *2018 13th IEEE International Conference on Automatic Face & Gesture Recognition (FG 2018)* (pp. 98-105). IEEE.




Luca Guarnera luca.guarnera@unict.it

Architectures for Deepfake Creation

6

Face swapping is not new



Semi-automatic

Blanz, V., Scherbaum, K., Vetter, T., & Seidel, H. P. (2004, September). **Exchanging faces in images**. In *Computer Graphics Forum* (Vol. 23, No. 3, pp. 669-676). Oxford, UK and Boston, USA: Blackwell Publishing, Inc

Luca Guarnera luca.guarnera@unict.it

Architectures for Deepfake Creation

7

... paved with good intentions

"[...] an attractive **solution to the privacy problem** is to remove the identities of people in photographs by **automatically replacing their faces** with ones from a collection of stock images [...]".



Original photographs After automatic face replacement

"[...] one could create a single **composite image** with [...], **everyone smiling** and with both **eyes open**"

Bitouk, D., Kumar, N., Dhillon, S., Belhumeur, P., & Nayar, S. K. (2008). **Face swapping: automatically replacing faces in photographs**. In *ACM SIGGRAPH 2008 papers* (pp. 1-8).



Luca Guarnera luca.guarnera@unict.it

Architectures for Deepfake Creation

8

... paved with good intentions

"[...] The system can be used for **image processing**, **virtual try-on** [...]".



Nirkin, Y., Masi, I., Tuan, A. T., Hassner, T., & Medioni, G. (2018, May). **On face segmentation, face swapping, and face perception**. In *2018 13th IEEE International Conference on Automatic Face & Gesture Recognition (FG 2018)* (pp. 98-105). IEEE.

Bitouk, D., Kumar, N., Dhillon, S., Belhumeur, P., & Nayar, S. K. (2008). **Face swapping: automatically replacing faces in photographs**. In *ACM SIGGRAPH 2008 papers* (pp. 1-8).




Luca Guarnera luca.guarnera@unit.it

Architectures for Deepfake Creation

9

Swapping used to be hard A CG pipeline



Nirkin, Y., Masi, I., Tuan, A. T., Hassner, T., & Medioni, G. (2018, May). **On face segmentation, face swapping, and face perception**. In *2018 13th IEEE International Conference on Automatic Face & Gesture Recognition (FG 2018)* (pp. 98-105). IEEE.




Luca Guarnera luca.guarnera@unit.it

Architectures for Deepfake Creation

10

But today, it's pretty easy A CG pipeline



Chang, F. J., Tran, A. T., Hassner, T., Masi, I., Nevatia, R., & Medioni, G. (2019). **Deep, landmark-free fame: Face alignment, modeling, and expression estimation.** *International Journal of Computer Vision*, 127(6-7), 930-956.

Nirkin, Y., Masi, I., Tuan, A. T., Hassner, T., & Medioni, G. (2018, May). **On face segmentation, face swapping, and face perception.** In *2018 13th IEEE International Conference on Automatic Face & Gesture Recognition (FG 2018)* (pp. 98-105). IEEE.




Luca Guarnera luca.guarnera@unict.it

Architectures for Deepfake Creation

11

But today, it's pretty easy A CG pipeline



Nirkin, Y., Masi, I., Tuan, A. T., Hassner, T., & Medioni, G. (2018, May). **On face segmentation, face swapping, and face perception.** In *2018 13th IEEE International Conference on Automatic Face & Gesture Recognition (FG 2018)* (pp. 98-105). IEEE.




Luca Guarnera luca.guarnera@unict.it

Architectures for Deepfake Creation

12

But today, it's pretty easy A CG pipeline



Nirkin, Y., Masi, I., Tuan, A. T., Hassner, T., & Medioni, G. (2018, May). **On face segmentation, face swapping, and face perception**. In *2018 13th IEEE International Conference on Automatic Face & Gesture Recognition (FG 2018)* (pp. 98-105). IEEE.




Luca Guarnera luca.guarnera@unict.it

Architectures for Deepfake Creation

13

But today, it's pretty easy A CG pipeline



Yes, again, pretty easy

Nirkin, Y., Masi, I., Tuan, A. T., Hassner, T., & Medioni, G. (2018, May). **On face segmentation, face swapping, and face perception**. In *2018 13th IEEE International Conference on Automatic Face & Gesture Recognition (FG 2018)* (pp. 98-105). IEEE.




Luca Guarnera luca.guarnera@unict.it

Architectures for Deepfake Creation

14

But today, it's pretty easy A CG pipeline



And there is code out there for all of this!

Nirkin, Y., Masi, I., Tuan, A. T., Hassner, T., & Medioni, G. (2018, May). **On face segmentation, face swapping, and face perception**. In *2018 13th IEEE International Conference on Automatic Face & Gesture Recognition (FG 2018)* (pp. 98-105). IEEE.



Luca Guarnera luca.guarnera@unit.it

Architectures for Deepfake Creation

15

Nomenclature: DeepFake

"[...] In autumn 2017, an **anonymous Reddit user** under the pseudonym **"deepfakes"** posted several **porn videos** on the Internet [...]"



Nicolas Cage
Source



Target

Swap

<https://en.wikipedia.org/wiki/Deepfake>




Luca Guarnera luca.guarnera@unit.it

Architectures for Deepfake Creation

16

Face Swap Vs Reenactment



Luca Guarnera luca.guarnera@unict.it

Architectures for Deepfake Creation

17

Face Reenactment

Thies, J., Zollhofer, M., Stamminger, M., Theobalt, C., & Nießner, M. (2016). *Face2face: Real-time face capture and reenactment of rgb videos*. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition* (pp. 2387-2395).

Luca Guarnera
luca.guarnera@unict.it

Source Actor



Target Actor

Real-time Reenactment



Reenactment Result


Architectures for Deepfake Creation

18



19

Attribute Manipulation



Yunjey Choi, Minje Choi, Munyoung Kim, Jung-Woo Ha, Sunghun Kim, and Jaegul Choo. **Stargan: Unified generative adversarial networks for multi-domain image-to-image translation**. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pages 8789–8797, 2018



Luca Guarnera luca.guarnera@unict.it

Architectures for Deepfake Creation

20

Attribute Manipulation: FaceAPP



IMPRESSIONE

VECCHIO

GIOVANE

BARBA

ACCONCIATURA

<https://play.google.com/store/apps/details?id=io.faceapp&hl=it&gl=US>

Luca Guarnera luca.guarnera@unict.it

Architectures for Deepfake Creation


21

The diagram is divided into three main sections illustrating different deep learning architectures:

- Autoencoders:** Shows an input image (xels) being processed by an encoder (consisting of convolutional layers, max pooling, and fully connected layers) to produce a latent representation (zels). This is then decoded by a decoder (consisting of fully connected, convolutional, and transposed convolutional layers) to produce an output image (reconstruction).
- Generative Adversarial Networks (GANs):** Illustrates the process where random noise is fed into a generator network to produce fake samples. These are compared against real samples by a discriminator network. The generator aims to minimize the generator loss, while the discriminator aims to maximize the discriminator loss.
- Diffusion Models:** Shows a sequence of images starting from a noisy input x_0 and progressing through intermediate steps $x_1, \dots, x_{T-1}$ to a final denoised output x_T .

Impressive Applications of Generative Models



- Generate Human Faces
- Generate Cartoon Characters
- Image-to-Image Translation
- Text-to-Image Translation
- Semantic-Image-to-Photo Translation
- Generate New Human Poses
- Face Aging
- Super Resolution
- Photo Inpainting
- ...



Luca Guarnera
luca.guarnera@unict.it

Architectures for Deepfake Creation

23





Autoencoders,
Generative Adversarial Networks,
Diffusion Models



24

Autoencoder

Unsupervised approach for learning a lower-dimensional feature representation from unlabeled training data




Luca Guarnera luca.guarnera@unit.it

Architectures for Deepfake Creation

25

Autoencoders



- From an input image to a feature representation (bottleneck layer)
- Encoder: a CNN in our case




Luca Guarnera luca.guarnera@unit.it

Architectures for Deepfake Creation


26

Autoencoder: training




27

Autoencoder: training



28

Autoencoder: training



- No labels required
- We can use unlabeled data to first get its structure




Luca Guarnera luca.guarnera@unit.it

Architectures for Deepfake Creation

29

Autoencoder: Use Cases

Embedding of
MNIST numbers




Luca Guarnera luca.guarnera@unit.it

Architectures for Deepfake Creation

30

Autoencoder for pre-training

■ Step 1: Unsupervised training with autoencoders




Luca Guarnera luca.guarnera@unit.it

Architectures for Deepfake Creation

31

Autoencoder for pre-training

■ Step 2: *Supervised* training with the labeled data



Throw away the decoder




Luca Guarnera luca.guarnera@unit.it

Architectures for Deepfake Creation

32

Autoencoder for pre-training

- Step 2: *Supervised training with the labeled data*



33

Why using autoencoders?


- Use 1: pre-training, as mentioned before
 - Image $\rightarrow$ same image reconstructed
 - Use the encoder as "feature extractor"
- Use 2: Use them to get pixel-wise predictions
 - Image $\rightarrow$ semantic segmentation
 - Low-resolution image $\rightarrow$ High-resolution image
 - Image $\rightarrow$ Depth map



34

Semantic Segmentation (FCN)

- Recall the Fully Convolutional Networks



[Long et al. 15] Fully Convolutional Networks for Semantic Segmentation (FCN)




Luca Guarnera luca.guarnera@unit.it

Architectures for Deepfake Creation

35

SegNet



Badrinarayanan et al. „SegNet: A Deep Convolutional Encoder-Decoder Architecture for Image Segmentation“. TPAMI 2016




Luca Guarnera luca.guarnera@unit.it

Architectures for Deepfake Creation

36

Deep autoencoders




U-Net or skip connections in autoencoders



Limiti degli Autoencoder

- Il problema fondamentale è che l'encoder, comprimendo, **perde informazioni spaziali** (dove si trovano i bordi, i dettagli fini). Il decoder da solo non riesce a recuperarle.




Luca Guarnera luca.guarnera@unit.it

Architectures for Deepfake Creation

42

Come funzionano le skip connections

- Ad ogni livello dell'encoder viene creato un "collegamento diretto" verso il livello **simmetrico** nel decoder, saltando tutta la parte centrale della rete (da qui *skip*).
- In pratica, l'output di un layer dell'encoder viene **concatenato** (non sommato, a differenza di ResNet) con il feature map corrispondente nel decoder



Luca Guarnera luca.guarnera@unit.it


Architectures for Deepfake Creation

43

Skip connections

- Le skip connections trasportano **informazioni ad alta risoluzione spaziale** (bordi, texture, posizione precisa delle strutture) che sarebbero andate perse nel collo di bottiglia. Il decoder riceve quindi due tipi di informazione:

Fonte	Informazione
Percorso profondo (bottleneck)	Contesto semantico ("cosa c'è")
Skip connection	Dettaglio spaziale ("dove si trova")




Luca Guarnera luca.guarnera@unit.it

Architectures for Deepfake Creation

44

Skip Connections



Luca Guarnera luca.guarnera@unit.it


Architectures for Deepfake Creation

45

Skip Connections

U-Net

Recall ResNet



O. Ronneberger et al. "U-Net: Convolutional Networks for Biomedical Image Segmentation". MICCAI 2015




Luca Guarnera luca.guarnera@unit.it

Architectures for Deepfake Creation

46

Skip Connections

U-Net: zoom in



O. Ronneberger et al. "U-Net: Convolutional Networks for Biomedical Image Segmentation". MICCAI 2015




Luca Guarnera luca.guarnera@unit.it

Architectures for Deepfake Creation

47


Skip Connections

- Concatenation connections



C. Hazirbas et al. "Deep depth from focus". ACCV 2018

SegNet



Badrinarayanan et al. „SegNet: A Deep Convolutional Encoder-Decoder Architecture for Image Segmentation“. TPAMI 2016

Skip Connections



- Widely used in Autoencoders
- At what levels the skip connections are needed depends on your problem



Luca Guarnera luca.guarnera@unict.it

Architectures for Deepfake Creation

50


Autoencoders,
Generative Adversarial Networks,
Diffusion Models




$x_0 \quad x_1 \quad \dots \quad x_{T-1} \quad x_T$




MATEMATICA
E INFORMATICA

98




99



100

Generating Elements of a Given Distribution

- Probability distribution functions of images are too much complex to be modelled with a **Gaussian Mixture Model** or other parametric specification of the estimated PDF.



Generative vs. Discriminative models

- Discriminative models




Generative vs. Discriminative models

■ Discriminative models




Generative vs. Discriminative models

■ Discriminative models




Generative vs. Discriminative models

■ Discriminative models




Generative vs. Discriminative models

■ Generative models




Generative vs. Discriminative models

- Generative models




Generative vs. Discriminative models

- Generative models



Generative vs. Discriminative models

Generative models




Luca Guarnera luca.guarnera@unit.it

Architectures for Deepfake Creation

111

Generative vs. Discriminative models

Generative models




Luca Guarnera luca.guarnera@unit.it

Architectures for Deepfake Creation

112

Generative vs. Discriminative models

▪ Generative models




Luca Guarnera luca.guarnera@unict.it

Architectures for Deepfake Creation

113

Generative vs. Discriminative models

• Generative models




Luca Guarnera luca.guarnera@unict.it

Architectures for Deepfake Creation


114

Generative vs. Discriminative models


Discriminative models




Generative models



Generative Adversarial Networks




Generative Adversarial Networks

Luca Guarnera luca.guarnera@unict.it

Architectures for Deepfake Creation

117


Generative Adversarial Networks

Luca Guarnera luca.guarnera@unict.it

Architectures for Deepfake Creation

118

Generative Adversarial Networks




Luca Guarnera luca.guarnera@unict.it

Architectures for Deepfake Creation

119

Generative Adversarial Networks




Luca Guarnera luca.guarnera@unict.it

Architectures for Deepfake Creation

120


Generative Adversarial Networks



Credit: <https://www.slideshare.net/xavigiro/deep-learning-for-computer-vision-generative-models-and-adversarial-training-upc-2016>

121


Generative Adversarial Networks



Credit: <https://www.slideshare.net/xavigiro/deep-learning-for-computer-vision-generative-models-and-adversarial-training-upc-2016>

122

Generative Adversarial Networks



Luca Guarnera luca.guarnera@unict.it

Architectures for Deepfake Creation

123

Generative Adversarial Networks

- The aim is to **learn** the **generator's distribution p_g over data x**
- Input **noise data** distribution p_z (e.g, Gaussian, Uniform)
- **The generator learns a mapping function $G(z; \theta_g)$** , where G is a differentiable function represented by a MLP with parameters θ_g
- A second MLP $D(x; \theta_d)$ outputs a single scalar $D(x)$ representing the probability that x came from the data distribution p_{data} rather than p_g

p_g generator's distribution
 p_z noise distribution (e.g, Gaussian, Uniform)
 p_{data} real data distribution
 $G(z; \theta_g)$ generator function (i.e., $x = G(z; \theta_g)$)
 $D(x; \theta_d)$ discriminator function

Luca Guarnera luca.guarnera@unict.it

Architectures for Deepfake Creation

124

Generative Adversarial Networks

- **Train D to maximize** the probability of assigning the correct label to both training examples and samples from G
- Simultaneously **train G to minimize** the distance betw




Image source <https://skymind.ai/wiki/generative-adversarial-network-gan>



Luca Guarnera luca.guarnera@unict.it

Architectures for Deepfake Creation

125

Generative Adversarial Networks

- D and G play the following minmax game

$$\min_G \max_D V(D, G) = \mathbb{E}_{x \sim p_{\text{data}}(x)} [\log D(x)] + \mathbb{E}_{z \sim p_z(z)} [\log(1 - D(G(z)))].$$




Image source <https://skymind.ai/wiki/generative-adversarial-network-gan>




Luca Guarnera luca.guarnera@unict.it

Architectures for Deepfake Creation

126

GAN example for human faces generation




Luca Guarnera luca.guarnera@unict.it

Architectures for Deepfake Creation

127

GAN example for human faces generation



The evolution of GAN models for the creation of synthetic multimedia contents



Image source: Salehi, Pegah, Abdolrah Chalechale, and Maryam Taghizadeh. "Generative Adversarial Networks (GANs): An Overview of Theoretical Model, Evaluation Metrics, and Recent Developments." *arXiv preprint arXiv:2005.13178* (2020).



Luca Guarnera luca.guarnera@unict.it

Architectures for Deepfake Creation


128

StarGAN

Several techniques present at the state of the art based on DeepFake are limited in the management of **more than two domains** (for example, to change **hair color**, **gender**, **age**, and **many others features in a face**), since they should be generated different models for each pair of image domains.

Attribute Manipulation

This manipulation, also known as **face editing** or **face retouching**, consists of modifying some attributes of the face such as the hair color, the gender, the age, adding glasses, etc.



Yunje Choi, Minje Choi, Munyoung Kim, Jung-Woo Ha, Sunghun Kim, and Jaegul Choo. **StarGAN: Unified generative adversarial networks for multi-domain image-to-image translation**. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pages 8789–8797, 2018



Luca Guarnera luca.guarnera@unict.it


Architectures for Deepfake Creation

129

StarGAN v2

Official PyTorch Implementation

<https://github.com/clovaai/stargan-v2>



Choi, Yunje, et al. "StarGAN v2: Diverse image synthesis for multiple domains." *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2020.



Multimedia Forensics: from Forgery to the Deepfake Phenomenon

130

StyleGAN

Entire Face Synthesis

This manipulation creates entire non-existent face images, usually through powerful GAN, e.g. StyleGAN.

The **Style Generative Adversarial Network**, or **StyleGAN**, is an extension to the GAN architecture that proposes **large changes to the generator model**, including the use of a mapping network to map points in latent space to an intermediate latent space, the use of the intermediate latent space to **control style at each point in the generator model**, and the introduction to noise as a source of variation at each point in the generator model.



<https://github.com/NVlabs/stylegan>

Karras, Tero, Samuli Laine, and Timo Aila. **A style-based generator architecture for generative adversarial networks**. *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2019.




Luca Guarnera luca.guarnera@unict.it

Architectures for Deepfake Creation

131

StyleGAN




Luca Guarnera luca.guarnera@unict.it


Architectures for Deepfake Creation

132

StyleGAN artifacts



In this example the teeth do not follow the pose but stay aligned to the camera, as indicated by the blue line



Karras, Tero, et al. **Analyzing and improving the image quality of stylegan**. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2020.



Luca Guarnera luca.guarnera@unict.it

Architectures for Deepfake Creation

133

StyleGAN2



Karras, Tero, et al. **Analyzing and improving the image quality of stylegan**. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2020.



Luca Guarnera luca.guarnera@unict.it


Architectures for Deepfake Creation

134

StyleGAN 2 - ADA



StyleGAN2 with adaptive discriminator augmentation (ADA)
— Official TensorFlow implementation



Training Generative Adversarial Networks with Limited Data

Tero Karras, Miika Aittala, Janne Hellsten, Samuli Laine, Jaakko Lehtinen, Timo Aila

<https://arxiv.org/abs/2006.06676>

Github repo: <https://github.com/NVlabs/stylegan2-ada>

Paper: <https://arxiv.org/abs/2006.06676>




Luca Guarnera luca.guarnera@unict.it

Architectures for Deepfake Creation

135

StyleGAN 3



For a typical GAN generator the "coarse, low-resolution features are hierarchically refined by upsampling layers, locally mixed by convolutions, and new detail is introduced through nonlinearities" (Karras, Tero, et al.) Current GANs do not synthesize images in a natural hierarchical manner: The coarse features mainly control the presence of finer features but not their precise positions. Although they fixed the artifacts in StyleGAN2, they did not completely fix the spatial invariance of finer features like hair.




Luca Guarnera luca.guarnera@unict.it

Architectures for Deepfake Creation

136

DCGAN - Pytorch

- https://pytorch.org/tutorials/beginner/dcgan_faces_tutorial.html




Luca Guarnera luca.guarnera@unict.it

Architectures for Deepfake Creation

137

DRAG Your GAN (2023)

Interactive Point-based Manipulation on the Generative Image Manifold




<https://arxiv.org/abs/2305.10973> (SIGGRAPH 2023)

<https://vc.ai.mpi-inf.mpg.de/projects/DragGAN/>


Luca Guarnera
luca.guarnera@unict.it

Architectures for Deepfake Creation

138



139



140

Introduction to Diffusion Model

"Creating noise from data is easy; creating data from noise is generative modeling."

-Song et al., ICLR 2021



Luca Guarnera luca.guarnera@unit.it

Architectures for Deepfake Creation

141


Images generated with Midjourney



two people walk the bridge under a large cherry blossom, in the style of atmospheric paintings, gray and aquamarine, airbrush art, dark white and dark gray, lovely --ar 35:64 --stylize 750 --v 6



a girl with blue hair with eyes closed, in the style of the stars art group (xing xing), yellow and orange, water drops, romantic illustrations, intense lines, gongbi, loose paint application --ar 71:98 --stylize 750 --v 6



sketches blueprint of futuristic sci fi, warp engine, warp bubble configurations, hyperdrive engines, equations for calibrating warp engine, star drive engines, placement inside ship, formulas and annotations, schematic by parts, golden ratio, fake detail, trending pivot fanbox, acrylic palette knife, style of style of makoto shinkai studio ghibli genshin impact james gilleard greg rutkowski chiho aoshi



Luca Guarnera luca.guarnera@unit.it

Architectures for Deepfake Creation

142



143



144

Il Nostro Obiettivo

Immagina di voler insegnare a un computer a creare immagini realistiche di lamponi. Sembra semplice... ma da dove si comincia?



Il Compito

Genera 100 immagini di lamponi — tutte realistiche, tutte diverse, tutte convincenti.



La Sfida

Un computer non "vede" il mondo come noi. Ha bisogno di un meccanismo matematico preciso per produrre qualcosa di visivamente coerente.



La Soluzione

I **Diffusion Model** risolvono questo problema in modo elegante, lavorando al contrario rispetto a quello che ci si aspetterebbe.

145

Facile vs. Difficile

✓ FACILE


Rumore Casuale

Generare pixel casuali è semplicissimo: qualsiasi computer lo fa in millisecondi. Non serve alcuna intelligenza — solo numeri a caso.

✗ DIFFICILE

Immagine di un Lampone


Generare un lampone realistico richiede struttura, colori coerenti, texture precisa. È un problema matematico enormemente più complesso.



146

Cos'è la "Diffusion"?

Il termine "diffusione" viene dalla fisica: descrive come una sostanza si disperde uniformemente in un mezzo. Nei modelli AI, il concetto è analogo.



L'obiettivo del modello è imparare a **percorrere questo collegamento** in modo controllato e affidabile, trasformando il caos in struttura.

147



Il Problema Diretto: Troppo Difficile

Passare **direttamente** da rumore casuale a un'immagine di lamponi in un unico salto è praticamente impossibile per una rete neurale.

Spazio enorme

Le possibili immagini sono infinite — trovare quella "giusta" partendo dal nulla è come cercare un ago in un oceano.

Nessuna guida


Senza passi intermedi, il modello non ha segnali su come orientarsi verso l'immagine desiderata.

Instabilità

Il training su salti così grandi tende a divergere: il modello non converge a soluzioni stabili e realistiche.

148

La Direzione Inversa: Facile!



Da Lampone a Rumore

Trasformare un'immagine reale di lampone in rumore casuale è **facilissimo**: basta aggiungere gradualmente del rumore gaussiano. Questo processo è deterministico, controllabile e matematicamente preciso. Non richiede intelligenza — solo matematica elementare.

✓ Processo Facile

149

Il Punto di Partenza e di Arrivo

Prima di scomporre il processo, fissiamo i due estremi fondamentali del sistema di diffusione.



Punto di Partenza

Raspberry Images — immagini reali, strutturate, ricche di dettaglio. Questo è ciò che il modello deve imparare a produrre.



Punto di Arrivo


Random Images — puro rumore gaussiano, completamente caotico. Facile da generare, impossibile da interpretare visivamente.

La strategia dei Diffusion Model è costruire un **ponte fatto di piccoli passi** tra questi due estremi.

150

Degradazione Graduale: Passo dopo Passo

Invece di un salto unico, l'immagine viene degradata in **tanti piccoli passi** — ognuno aggiunge solo un po' di rumore.



Ogni passo è minuscolo e **facilmente invertibile**. Questa è la chiave dell'intero sistema: piccoli passi = piccoli problemi da risolvere.



151

Il Compito del Modello

La rete neurale non deve fare tutto in una volta. Il suo unico compito è rispondere a una domanda semplice:

"Dato questo livello di rumore, qual era l'immagine un passo prima?"

Una freccia rossa attraversa la nuvola di rumore e punta verso l'immagine strutturata del lampone — il modello impara a percorrere questa direzione, **un piccolo passo alla volta**.



152

Il Percorso Inverso: Denoising

Durante la **generazione**, il modello parte dal puro rumore e applica il processo inverso ripetutamente.



Ogni piccolo passo di "denoising" è gestibile: la rete neurale rimuove un po' di rumore alla volta, guidando l'immagine verso una struttura coerente e realistica.

153

Il Quadro Completo


I due percorsi insieme mostrano l'eleganza del sistema: uno è facile (e serve per addestrare), l'altro è il risultato finale.

Percorso Verde → Rumore

Forward Process (facile): aggiungi rumore gradualmente. Serve per creare i dati di training. Completamente automatico.

Percorso Rosso → Immagine


Reverse Process (appreso): rimuovi rumore passo per passo. È ciò che la rete neurale impara durante il training.



154

Addestramento e Architettura

Come fa concretamente la rete neurale ad imparare il processo inverso?
Esploriamo la fase di training dei Diffusion Model.



155

Il Dataset: Tante Immagini Reali

Prima di iniziare il training, servono molte immagini reali di lamponi — migliaia o milioni di esempi da cui il modello potrà imparare.



Immagini Originali

Fotografie reali di lamponi in condizioni diverse — luce, angolazione, sfondo variabili.



Con Poco Rumore

La stessa immagine con un livello minimo di rumore aggiunto — ancora riconoscibile.



Con Molto Rumore

Livelli alti di rumore: l'immagine originale è quasi irriconoscibile ma ancora tracciabile.

156

La Rete Neurale di Diffusione

Il cuore del sistema è una **rete neurale** specializzata nel predire e rimuovere il rumore. Architettura tipica: la **U-Net**.



Input

Immagine rumorosa + timestep t . La rete sa esattamente quanto rumore è stato aggiunto.



Elaborazione

Layer convoluzionali profondi analizzano la struttura spaziale dell'immagine a diverse scale.



Output

Predizione del rumore da rimuovere — o direttamente l'immagine denoised al passo precedente.

160

La Funzione di Loss

Come misura il modello il suo errore durante il training? Con una funzione di loss semplice ed efficace.

Predizione del rumore

Il modello predice ϵ (il rumore aggiunto)

Rumore reale

ϵ è il rumore gaussiano effettivamente aggiunto

Loss = MSE

$L = ||\epsilon - \hat{\epsilon}||^2$ — minimizza la differenza quadratica

Perché funziona?


Predire il rumore è equivalente a predire l'immagine pulita — ma risulta **numericamente più stabile** durante il training.

Più il modello si allena, più diventa preciso nel stimare esattamente quanto rumore è presente e dove.

161

Il Loop di Training

Il training ripete questo ciclo milioni di volte su migliaia di immagini diverse.



162

Cosa Impara la Rete?

Dopo milioni di iterazioni, la rete neurale ha internalizzato qualcosa di straordinario.

- | | | |
|---|--|--|
| <p>La struttura visiva dei lamponi</p> <p>Forma, colore, texture, distribuzione dei drupeoli — tutto ciò che rende un lampone riconoscibile.</p> | <p>Come il rumore maschera la struttura</p> <p>A ogni livello di rumore, sa esattamente quali pattern strutturali sono stati oscurati e come ripristinarli.</p> | <p>Come invertire il processo</p> <p>Dato un qualsiasi livello di rumore, sa sempre qual è il passo successivo verso l'immagine pulita.</p> |
|---|--|--|

163

Generazione: Usare il Modello Addestrato

Una volta addestrato, il modello è pronto per generare nuove immagini. Il processo di generazione è elegante:

01

Campiona rumore casuale

Genera un'immagine di puro rumore gaussiano — il punto di partenza è sempre casuale.

02

Applica il modello ripetutamente

Per ogni timestep da T a 0 , la rete rimuove un po' di rumore, guidando l'immagine verso la struttura.

03

Ottieni l'immagine finale

Dopo ~1000 passi, emerge un'immagine realistica e nuova — mai vista prima, ma convincente.

164

Perché Tanti Passi?

~1000 passi

Standard DDPM — qualità massima, ma lento (minuti per immagine)

~50 passi

DDIM — qualità quasi identica, molto più veloce (secondi)

~4-8 passi

Modelli distillati (Turbo) — quasi in tempo reale, qualità buona

Il Trade-off


Più passi = più qualità, ma più tempo di calcolo. La ricerca recente ha trovato modi brillanti per **ridurre drasticamente i passi** senza perdere qualità.

Oggi i modelli più veloci generano immagini in **meno di un secondo** su hardware consumer.

165

Architettura U-Net: Una Panoramica

La U-Net è l'architettura più comune nei Diffusion Model. Il suo design "a U" permette di catturare dettagli a scale diverse.



166

Il Ruolo del Timestep

La rete deve sapere "dove si trova" nel processo di denoising. Il timestep t viene integrato nell'architettura tramite **positional embeddings**.

t grande (molto rumore)

Il modello si concentra sulla struttura globale: ricostruisce forme e composizione generale dell'immagine.

t medio

Bilanciamento tra struttura e dettaglio: vengono definiti colori, texture grossolane e relazioni spaziali.

t piccolo (poco rumore)


Il modello si concentra sui dettagli fini: rifinitura di bordi, texture sottili, coerenza locale.

167

Attention: La Memoria del Modello

Le moderne U-Net per diffusione integrano **Self-Attention** e **Cross-Attention** — meccanismi che permettono alla rete di "guardare" a diverse parti dell'immagine contemporaneamente.


Questo è fondamentale per mantenere la **coerenza globale**: che il lampone abbia la stessa luminosità su tutta la superficie, per esempio.



168

Stable Diffusion: L'Innovazione dello Spazio Latente


Lavorare direttamente sui pixel è costoso. Stable Diffusion introduce un'idea brillante: fare tutto in uno **spazio latente compresso**.



La diffusione avviene su una rappresentazione **8x più piccola** — molto più efficiente, stessa qualità visiva finale.

169

Riepilogo del Training



170

Ma Solo Lamponi?

Finora abbiamo parlato di lamponi — ma i Diffusion Model possono imparare **qualsiasi distribuzione visiva**. La domanda è: come si guida la generazione verso qualcosa di specifico?



Mele

La stessa architettura, addestrata su immagini di mele, genererà mele.



Mango

Addestrata su mango, genererà mango — con textures tropicali e colori caldi.



Pesche

Ogni frutto ha la sua distribuzione visiva unica che il modello può imparare.

Serve un meccanismo più flessibile: il **condizionamento**.

171

Scalabilità: Da Lamponi al Mondo

I modelli moderni come Stable Diffusion, DALL-E e Midjourney vengono addestrati su **miliardi di immagini** da tutto il web.

5B+

Immagini

Dataset LAION-5B usato per SDXL

\$M

Costo Training

Milioni di dollari in compute per i modelli più grandi

1000

Timestep


Passi standard per il forward/reverse process

860M

Parametri

U-Net di Stable Diffusion 1.5

172



Condizionamento e Creatività

Come si dice al modello cosa generare? Entra in gioco il **condizionamento testuale** — la capacità di guidare la generazione con parole.

173

Introduzione alle Etichette Testuali

Il primo approccio al condizionamento è semplice: associare ogni immagine nel dataset a un'etichetta testuale.



"apple"

Tutte le immagini di mele vengono associate all'etichetta testuale "apple" durante il training.



"peach"

Immagini di pesche → etichetta "peach". Ogni frutto ha la sua firma visiva distinta.



"mango"

Immagini di mango → etichetta "mango". Il modello impara l'associazione visivo-testuale.



"raspberry"

Il nostro lampone preferito: ora richiamabile con una parola sola.

174

Come Funziona il Condizionamento

L'etichetta testuale viene integrata nel processo di denoising tramite il meccanismo di **Cross-Attention**.



La rete, ad ogni passo di denoising, "guarda" sia l'immagine rumorosa che l'embedding del testo per decidere quale rumore rimuovere.

175

Da Etichette a Descrizioni Libere

Etichette Semplici

Parole singole come "apple", "mango", "raspberry" — facili da gestire ma limitanti. Cosa succede se vogliamo qualcosa di più creativo?

"a red apple"

Aggiungi attributi: colore, dimensione, stato.

Testo Libero

Passando a **descrizioni in linguaggio naturale**, il modello acquista una flessibilità straordinaria. Il testo può descrivere:

- Soggetti e oggetti
- Stile artistico
- Illuminazione e atmosfera
- Composizione e punto di vista
- Relazioni tra oggetti

"apple on a wooden table"

Aggiungi contesto spaziale e ambiente.

176


Esempio Creativo:

"Raspberry Beret"



"A beret made of raspberries"


Ecco dove i Diffusion Model diventano straordinari: possono **combinare concetti che non esistono in natura**. Il modello ha imparato separatamente cosa è un "beret" e cosa sono i "raspberries" — e ora li combina creativamente.



177

La Potenza della Combinazione Semantica


Il modello non ha mai visto un "berretto di lamponi" nel dataset — eppure riesce a generarlo. Perché?



178


Integrazione con i Large Language Models

Per comprendere testi complessi, i Diffusion Model si integrano con i LLM (Large Language Models) come encoder testuali avanzati.



179

CLIP: Il Ponte Visivo-Testuale



Cosa fa CLIP?

CLIP (Contrastive Language-Image Pre-training di OpenAI) è addestrato su centinaia di milioni di coppie immagine-testo dal web.

Impara a mappare immagini e testi nello **stesso spazio vettoriale** — così "una mela rossa" e la foto di una mela rossa sono vicine nello spazio semantico.

Questo encoder testuale è il "traduttore" che permette al Diffusion Model di capire descrizioni complesse.

180

Prompt Engineering: L'Arte di Comunicare con il Modello

Il modo in cui si scrive il prompt influenza enormemente il risultato finale. Ecco come strutturare prompt efficaci.

1 Soggetto Descrivi il soggetto principale chiaramente. Es: "a beret made entirely of fresh raspberries"	2 Stile Aggiungi riferimenti stilistici. Es: "photorealistic", "oil painting", "watercolor illustration"
3 Dettagli Specifica illuminazione, angolo, atmosfera. Es: "soft natural lighting, studio background"	4 Qualità Parole chiave per la qualità: "8k, detailed, sharp focus, professional photography"

181

Classifier-Free Guidance

Come si regola **quanto fortemente** il modello segue il prompt testuale? Con la tecnica del **Classifier-Free Guidance (CFG)**.

CFG = 1

Il modello ignora quasi il testo — output casuale e vario.

CFG = 7

Bilanciamento ideale: segue il prompt mantenendo varietà naturale.


CFG = 20+

Segue il prompt in modo ossessivo — immagini oversaturate e artefatti.

Il Meccanismo

Il modello esegue **due passaggi** ad ogni step: uno condizionato dal testo e uno incondizionato. Il CFG scale determina quanto "spingere" nella direzione del testo. È come avere un'ago di bussola: più alto il valore, più forte la spinta verso il target semantico.

182




Output: "Beret of Raspberries"

Un esempio concreto di output: il modello ha combinato la **geometria di un cappello beret** con la **texture**, il **colore** e la **forma** dei lamponi — creando qualcosa di mai esistito ma perfettamente credibile.

183

Esempi di Output: Variazioni Semantiche

Piccoli cambiamenti nel prompt producono risultati visivamente distinti ma coerenti con la semantica richiesta.



"raspberry beret"

Cappello composto da lamponi freschi — textures rosse e succose in forma di cappello.



"apple crown"

Corona reale fatta di mele — il modello combina regalia e frutta in modo convincente.



"mango sunset"

Un tramonto con i colori e le sfumature di un mango maturo — metafora visiva realizzata.

184

Dalla Parola all'Immagine Complessa

Con LLM avanzati come encoder, il modello può interpretare descrizioni molto elaborate e articolate.

Prompt Semplice

"raspberry" → Immagine base di lamponi

Prompt Medio

"a basket of ripe raspberries in morning sunlight" → Composizione contestualizzata

Prompt Complesso

"a surrealist painting of a raspberry kingdom where tiny raspberry people wear raspberry crowns and live in raspberry castles" → Scena narrativa elaborata

185

Applicazioni Reali dei Diffusion Model

Questa tecnologia non è solo teorica — sta trasformando industrie reali oggi.



Arte e Design

Generazione di concept art, illustrazioni, loghi e asset visivi in secondi.



Film e VFX

Inpainting, outpainting, generazione di sfondi e texture per la produzione cinematografica.



Medicina

Augmentazione di dataset medici, generazione di immagini diagnostiche sintetiche.



Moda

Prototipazione rapida di design, visualizzazione di capi su diversi corpi e stili.

186

Sfide e Limitazioni

Cosa funziona bene

✓ Texture e pattern

Superfici, materiali, sfondi naturali

✓ Composizione artistica

Stili, atmosfere, riferimenti pittorici

✓ Variazioni semantiche

Combinare concetti in modo creativo

Dove ancora fatica

✗ Mani e dita

Strutture articolate complesse difficili da modellare

✗ Testo nelle immagini

Scritte e caratteri spesso sfocati o errati


✗ Conteggio preciso

"Esattamente 7 lamponi" è ancora una sfida

187

Riepilogo: Il Ciclo Completo


Mettiamo tutto insieme in un unico quadro comprensivo del funzionamento dei Diffusion Model.



188

I Modelli Più Famosi

Oggi esistono diversi Diffusion Model di riferimento, ognuno con caratteristiche distintive.



189

Oltre le Immagini: Video e Audio

Il paradigma della diffusione non si limita alle immagini fisse — si estende a qualsiasi tipo di dato continuo.



Video Diffusion

Sora (OpenAI), Runway Gen-3, Kling: generano video coerenti e fluidi da descrizioni testuali.



Audio Diffusion


AudioLDM, MusicGen: generano musica e effetti sonori realistici da prompt testuali.



3D e Molecole

Diffusione applicata a strutture 3D, proteine (AlphaFold3) e design molecolare in farmacologia.

190



Etica e Responsabilità

Con grande potere creativo vengono grandi responsabilità. I Diffusion Model sollevano questioni importanti che la comunità sta affrontando attivamente.

Copyright e dataset

Molti modelli sono stati addestrati su immagini coperte da copyright senza consenso esplicito degli artisti.

Deepfake e disinformazione

La facilità di generare immagini realistiche di persone reali pone rischi seri per l'informazione pubblica.


Bias nei dati

I bias presenti nel dataset di training si riflettono negli output — stereotipi visivi da monitorare e correggere.

191

Dove Siamo Arrivati

I Diffusion Model hanno percorso una strada incredibile in pochissimi anni — e il ritmo dell'innovazione non accenna a rallentare.



192

Concetti Chiave da Ricordare

1 Il trucco del percorso inverso

Anziché imparare a creare immagini dal nulla, il modello impara a **invertire il rumore** — un problema molto più semplice da affrontare.

2 Piccoli passi, grande risultato

Scomponendo il problema in migliaia di micro-passi, ogni singolo passo diventa **facilmente apprendibile** dalla rete neurale.

3 Il testo come bussola


Il condizionamento testuale tramite Cross-Attention permette di **guidare la generazione** verso qualsiasi concetto descrivibile con le parole.

193

Dal Rumore alla Creatività

I Diffusion Model ci mostrano qualcosa di profondo: la **creatività può essere matematica**. Dal caos più puro — rumore casuale — emergono immagini di straordinaria bellezza e coerenza, un piccolo passo alla volta.

"La generazione di immagini AI non è magia — è la somma di milioni di piccoli passi imparati con pazienza."



194

Risorse per Approfondire

Vuoi andare oltre? Ecco i punti di partenza consigliati per esplorare i Diffusion Model in modo più approfondito.



Paper Fondamentali

"Denoising Diffusion Probabilistic Models" (Ho et al., 2020) — il paper che ha reso pratici i Diffusion Model.



Strumenti Pratici

Hugging Face Diffusers — libreria Python open source per sperimentare con tutti i principali modelli.



Corsi Online

Fast.ai "Practical Deep Learning", Andrej Karpathy su YouTube — spiegazioni intuitive e pratiche.




Playground

Stability AI Playground, Adobe Firefly, Ideogram — sperimenta gratuitamente con prompt creativi.


195

Diffusion Model Formulas

The formal definition of the forward process in T steps:



Formal definition of forward and reverse processes in T steps:



Luca Guarnera luca.guarnera@unict.it


Architectures for Deepfake Creation

196

Stable Diffusion

Examples of images generated by Stable Diffusion

- From Custom Stable Diffusion models to create celebrities in iconic roles to AI Artists.



Architectures for Deepfake Creation

197



198



199

Technologies in comparison

Luca Guarnera
luca.guarnera@unict.it

Architectures for Deepfake Creation

Uni
ct
MATEMATICA
E INFORMATICA

200

Which model to use?

- **VAEs** offer fast and different sampling with easier training, but of lower quality than GANs.
- **GAN** is still a more practical solution which needs fast sampling (e.g., real-time apps.)
- **Diffusion Model** seems to be a nice option for high-quality generation

Generative Adversarial Networks

High Quality Samples

Fast Sampling

Mode Coverage / Diversity

Denoising Diffusion Models

Variational Autoencoders, Normalizing Flows

Luca Guarnera luca.guarnera@unict.it

Architectures for Deepfake Creation

201