



Università
di Catania




Audio Processing ed Enhancing

Prof. Massimo Orazio Spata

Dipartimento di Matematica e Informatica

Università degli Studi di Catania



01

Introduzione

* Blocco 1, 2 delle slide con contributo del Dr. Andrea Di pierno



Cosa è il suono?

Il suono è un fenomeno fisico generato da vibrazioni che si propagano attraverso un mezzo, solitamente l'aria, sotto forma di variazioni di pressione nel tempo.

Tre proprietà fondamentali:


- ampiezza
- frequenza
- fase

che determinano l'intensità, l'acutezza e la complessità di un suono.

Quando lavoriamo con i segnali audio, il nostro obiettivo è catturare e analizzare queste variazioni in modo che un computer possa comprenderle.




Com'è fatto un suono?



E la fase?


Cos'è la fase?



La **fase** è la distanza tra due punti dell'onda in un determinato istante


Dalle onde all'audio digitale

- Un computer non può elaborare onde di pressione continue.
- Il primo passo consiste nel convertirle in una rappresentazione digitale.
- Questo viene fatto campionando l'ampiezza dell'onda ad intervalli regolari e quantizzandola in valori numerici.
- Il risultato è un segnale a tempo discreto che approssima il suono originale. La qualità di questa rappresentazione dipende dalla frequenza con cui campioniamo l'onda e dalla precisione con cui memorizziamo ciascun valore. Questa frequenza è chiamata frequenza di campionamento.




Frequenza di campionamento o sampling rate

- La frequenza di campionamento definisce quanti campioni al secondo vengono acquisiti dal segnale analogico.
- Secondo il teorema di Nyquist-Shannon, dobbiamo campionare almeno il doppio della frequenza più alta che vogliamo rappresentare; altrimenti, introduciamo una distorsione chiamata aliasing.
- In pratica, l'elaborazione del parlato utilizza spesso 16 kHz, mentre le applicazioni musicali utilizzano frequenze più elevate come 44,1 o 48 kHz. La scelta della frequenza di campionamento influisce sia sulla fedeltà che sul costo computazionale dell'elaborazione successiva.




Bit Depth


- La profondità di bit determina quanti livelli di ampiezza discreti sono disponibili per rappresentare il segnale.
- Una maggiore profondità di bit consente una gamma dinamica più ampia e riduce il rumore di quantizzazione introdotto durante la digitalizzazione.
- Esempio: l'audio a 16 bit offre 65.536 livelli possibili, che in genere sono sufficienti per l'elaborazione del parlato, mentre l'audio professionale utilizza spesso 24 bit per una maggiore precisione.



PCM

- Pulse Code Modulation (PCM) è la rappresentazione standard non compressa dell'audio digitale.
- Formati come WAV o FLAC preservano la qualità originale del segnale e sono quindi ideali per l'analisi e l'apprendimento automatico.
- I formati compressi come MP3 o AAC, invece, riducono le dimensioni del file eliminando le informazioni percettivamente meno rilevanti, ma questo comporta la presenza di artefatti sottili che possono influire su attività come il rilevamento dei deepfake.






02

Audio features



Waveforms

- Rappresentando graficamente il segnale audio nel tempo, si rivelano le sue fluttuazioni di ampiezza, fornendoci informazioni sulla struttura del parlato o di altri suoni.
- La forma d'onda ci permette di identificare silenzi, picchi improvvisi, distorsioni e schemi temporali generali.
- Tuttavia, non mostra direttamente quali frequenze sono presenti, informazione che spesso è la più importante per l'analisi audio. Per eseguire un'analisi più approfondita, è necessario pre-elaborare l'audio.




Preprocessing

Prima di qualsiasi attività analitica, l'audio viene in genere sottoposto a fasi di pre-elaborazione quali:

- normalizzazione,
- rimozione del silenzio,
- riempimento,
- taglio,
- Rilevamento dell'attività vocale (VAD),
- ecc.

Queste operazioni garantiscono che i dati siano coerenti, confrontabili tra i campioni e pronti per essere utilizzati in algoritmi di estrazione delle caratteristiche o reti neurali.



Perché la frequenza è così importante?

- Due segnali possono apparire simili nel dominio del tempo, ma presentare caratteristiche spettrali completamente diverse.
- L'analisi di frequenza ci permette di comprendere l'altezza del suono, la struttura armonica, la risonanza e la presenza di rumore.
- Pertanto, la maggior parte dei metodi di elaborazione del parlato si basa fortemente sulle rappresentazioni tempo-frequenza.




The Fourier Transform

La Trasformata di Fourier scompone un segnale in una combinazione di sinusoidi a diverse frequenze.


Questo permette di determinare la quantità di energia presente a ciascuna frequenza e costituisce la base per quasi tutte le tecniche di estrazione di caratteristiche audio.

La Trasformata di Fourier Veloce (FFT) è la versione algoritmica che consente un'elaborazione efficiente anche su segnali lunghi.



The Fourier Transform (2)


- La trasformata di Fourier produce due output: ampiezza e fase.
- L'ampiezza descrive l'intensità di ciascuna componente di frequenza, mentre la fase codifica l'allineamento di queste componenti all'interno del segnale.



The Short-Time Fourier Transform (STFT)

Poiché il parlato e altri segnali naturali cambiano nel tempo, abbiamo bisogno di una rappresentazione che catturi l'evoluzione del contenuto in frequenza.


- **La STFT raggiunge questo obiettivo analizzando brevi finestre sovrapposte del segnale e calcolando una FFT per ciascuna finestra.**
- La scelta della dimensione della finestra e della lunghezza del salto determina il compromesso tra risoluzione temporale e risoluzione in frequenza.



Spectrograms

Uno spettrogramma è una visualizzazione della STFT sotto forma di immagine. Sull'asse orizzontale è rappresentato il tempo, sull'asse verticale la frequenza, mentre l'intensità del colore rappresenta l'energia.


Questa rappresentazione rende immediatamente visibili gli schemi presenti nel parlato o nella musica ed è ampiamente utilizzata nei modelli di apprendimento automatico, dai classificatori classici alle moderne architetture neurali.



Spectrograms (2)

Gli spettrogrammi rivelano una struttura complessa: schemi armonici, eventi transitori, componenti di rumore e la distinzione tra parlato sonoro e parlato sordo.


Ad esempio, le vocali appaiono come bande orizzontali stabili (formanti), mentre le consonanti spesso producono picchi ad alta frequenza. Molti artefatti prodotti dai modelli generativi diventano visibili anche in questo ambito.



La scala di Mel

Gli esseri umani percepiscono l'altezza dei suoni in modo non lineare, con una maggiore sensibilità alle basse frequenze rispetto a quelle alte. La scala Mel è una scala di frequenza percettiva che approssima questo comportamento.


Applicando un filtro Mel allo spettro, creiamo una rappresentazione più compatta e percettivamente significativa, ampiamente utilizzata nei processi di elaborazione del parlato e di apprendimento profondo.



Mel Spectrograms


Mappando l'asse delle frequenze dello spettrogramma sulla scala Mel e applicando la compressione logaritmica, otteniamo lo spettrogramma Mel.

Questa rappresentazione enfatizza i dettagli percettivamente rilevanti e riduce la dimensionalità, rendendola un input eccellente per i moderni modelli di apprendimento automatico, soprattutto per le applicazioni di riconoscimento vocale.




MFCCs


- I coefficienti cepstrali a frequenza Mel (MFCC) riassumono l'involuppo spettrale di un segnale applicando una trasformata discreta del coseno (DCT) allo spettro logaritmico Mel.
- Sono stati la pietra angolare del riconoscimento vocale e dell'identificazione del parlante per decenni, poiché catturano le caratteristiche di risonanza del tratto vocale.



Limitazioni delle MFCCs

- I coefficienti MFCC sono compatti ed efficaci per molti compiti, ma tralasciano dettagli importanti come la fase e la struttura armonica fine.
- Di conseguenza, potrebbero non essere in grado di distinguere tra parlato sintetico di alta qualità e registrazioni autentiche, risultando meno adatti al rilevamento dei deepfake moderni senza caratteristiche aggiuntive.





03

Miglioramento del Segnale Audio Forense



Miglioramento del Segnale Audio Forense

DeepFilterNet · SepFormer · Wiener Filter · Whisper ASR

Pipeline sperimentale per enhancement, separazione del parlato e trascrizione automatica con validazione umana

audio evidence

speech enhancement

forensic STT

Report tecnico sperimentale · Università degli Studi di Catania · Maggio 2025
Prof. Massimo Orazio Spata,
Dipartimento di Matematica e Informatica



AUDIO FORENSE: PRINCIPI CARDINE

Il trattamento del segnale in ambito giudiziario richiede un equilibrio critico tra due obiettivi divergenti:

Intelligibilità del Parlato

Massimizzare la comprensione del contenuto verbale per l'analista e la giuria.

Integrità Informativa

Evitare artefatti che possano alterare l'evidenza probatoria o indurre in errore.



SCENARI DI DEGRADO ACUSTICO



Bisbiglio

Rumore di fondo con parlato a bassa energia, difficile da isolare senza perdere componenti spettrali.



Saturazione

Clipping del segnale causato dal sovraccarico dei circuiti di acquisizione (distorsione non lineare).



Traffico

Rumore ambientale stazionario e impulsivo con forti componenti a bassa frequenza.



Voci Sovrapposte

Il "Cocktail Party Problem": interferenza strutturata tra più locutori simultanei.

LA PIPELINE SPERIMENTALE



Un approccio ibrido che combina il potere del **Deep Learning** con la precisione del **filtraggio classico**:

- ✓ **DeepFilterNet (DFN):** Soppressione del rumore basata su reti neurali nel dominio della frequenza.
- ✓ **SepFormer:** Separazione cieca delle sorgenti per scenari multi-parlante.
- ✓ **Filtro di Wiener:** Post-processore spettrale per l'eliminazione degli artefatti musicali.
- ✓ **Whisper ASR:** Trascrizione automatica ad alta precisione (OpenAI).

ARCHITETTURA DEL SISTEMA

1

Pre-Processing

Filtro Passa-Alto (60-80 Hz) e normalizzazione a 0,97 dBFS / -24 LUFS.



2

Enhancement

Nucleo DeepFilterNet integrato con logiche specifiche (Soft Declipping o SepFormer).



3

Refinement

Filtro di Wiener adattivo per stabilizzare il noise floor residuo.



Output: Trascrizione Whisper Large-v3


TECNOLOGIA DI FILTRAGGIO

Dual-Signal Transformation

DeepFilterNet utilizza un filtro adattivo *ERB* (*Equivalent Rectangular Bandwidth*) per le basse frequenze e una *LSTM* per le alte, garantendo bassa latenza e alta fedeltà.

$$H(f, t) = \frac{\hat{S}(f, t)}{\hat{S}(f, t) + \hat{N}(f)}$$

Il Filtro di Wiener stima la PSD (Power Spectral Density) del rumore per minimizzare l'errore quadratico medio.



THE COCKTAIL PARTY PROBLEM

La sfida più complessa: separare locutori multipli che condividono la stessa banda spettrale.

SepFormer Blind Separation

Utilizza l'architettura Transformer per modellare dipendenze a lungo termine e isolare le tracce.

ASR-Guided Selection

Un'innovazione della pipeline: Whisper viene usato per valutare quale traccia separata abbia il punteggio di log-probabilità migliore, selezionando automaticamente la voce target.



METODOLOGIA DI VALUTAZIONE QUALITATIVA

Metrica	Standard / Riferimento	Descrizione Funzionale
SNR / ASNR	Rapporto Segnale-Rumore	Misura l'incremento di energia del segnale rispetto al rumore (dB).
PESQ WB	ITU-T P.862.2	Valutazione percettiva della qualità (scala -0.5 a 4.5).
STOI	Objective Intelligibility	Stima dell'intelligibilità nel dominio tempo-frequenza (0 a 1).
LUFS	ITU-R BS.1770	Normalizzazione del volume basata sulla percezione umana.

Nota: Il segnale originale è usato come reference "proxy" per PESQ, misurando la fedeltà alla sorgente degradata.

METRICHE SPEECH-TO-TEXT QUANTITATIVE

WER

Word Error Rate

CER

Character Error Rate


Validazione Quantitativa

Calcolate tramite la **distanza di Levenshtein** tra il ground truth manuale e l'output di Whisper:

$$WER = \frac{S + D + I}{N}$$

S = Sostituzioni, D = Cancellazioni, I = Inserzioni. Whisper large-v3 predilige le cancellazioni, minimizzando le "allucinazioni" (fondamentale in ambito forense).

GUADAGNO SNR PER CONDIZIONE



PESQ Medio (Saturazione)

4.23


STOI Medio (Bisbiglio)

0.98

*Il ASNR negativo nel bisbiglio riflette la compressione del range dinamico per favorire l'intelligibilità (STOI elevato).

ACCURATEZZA TRASCRIZIONE (WER%)

Confronto tra audio **Originale** vs **Enhanced**:



Analisi: L'enhancement migliora la trascrizione in 3 scenari su 4. Nelle voci concorrenti, la regressione è un compromesso accettabile per ottenere tracce separate più utili all'analista forense.

Definizioni di base: audio forense

Audio forense

Disciplina che acquisisce, conserva, analizza e interpreta segnali audio con valore probatorio.


Il fine non è solo rendere il suono più gradevole, ma migliorare l'intelligibilità senza alterare il contenuto informativo.

Ogni trasformazione deve essere documentata, riproducibile e verificabile da terzi.

Differenza critica

enhancement tecnico $\neq$ modifica della prova

L'audio migliorato supporta l'ascolto e l'ASR, ma l'originale resta il riferimento probatorio.



Nel report: 12 registrazioni WAV mono, 4 condizioni di degrado, frequenza di lavoro comune a 48 kHz.



Principi probatori da rispettare

Integrità

hash SHA-256
originale e
enhanced

01

Tracciabilità

log di elaborazione
per ogni file

02

Riproducibilità

parametri, versioni,
workflow
deterministico

03

Validazione

human-in-the-loop
per la trascrizione

04

La pipeline produce output tecnici; l'ammissibilità richiede catena di custodia e revisione esperta.

Problema: quattro scenari acustici critici

Rumore + bisbiglio

parlato debole, fricative mascherate, rischio cancellazioni



Saturazione

clipping dei picchi, forma d'onda appiattita, distorsione armonica



Traffico urbano

basse frequenze energetiche, rumore impulsivo e stazionario



Voci concorrenti

sorgenti vocali sovrapposte, cocktail party problem



In tutti gli scenari il rischio operativo è lo stesso: migliorare il segnale senza introdurre artefatti che alterino il contenuto verbale.

Obiettivi e requisiti della soluzione

1

Aumentare intelligibilità

rendere udibile il contenuto verbale per revisione umana

2

Stabilizzare l'ASR (Automatic Speech Recognition)

fornire a Whisper input meno degradati e segmentabili

3

Preservare la prova

documentare ogni trasformazione e mantenere l'originale

4

Gestire casi eterogenei


usare catene dedicate per rumore, clipping, traffico e multi-speaker



Regola forense


L'output automatico è un supporto all'analista, non una decisione autonoma.

Soluzione proposta: pipeline multi-stadio




Design: un pre-processing comune, una catena specifica per condizione e un layer finale di trascrizione + logging.

Architettura della soluzione proposta



Animazione grafica: da segnale degradato a voce intellegibile





Sequenza di animazione

1. ingresso del segnale rumoroso
2. sweep del filtro neurale
3. attenuazione dei residui spettrali
4. uscita del parlato ripulito
5. passaggio a Whisper e validazione umana

La metafora visuale è coerente con la pipeline: rumore caotico → trasformazione controllata → segnale meno ambiguo per ascolto e ASR.

Nel file PowerPoint il riquadro a sinistra è un GIF animato: avvia la presentazione per visualizzare lo sweep.

Voci concorrenti: separazione + criterio semantico



log-probabilità + no-speech probability → scelta della sorgente target

Standard e quadro di conformità

ISO/IEC 27037

identificazione, raccolta, acquisizione e conservazione della prova digitale

ISO/IEC 27041

assicurare adeguatezza e idoneità dei metodi investigativi

ISO/IEC 27042

analisi e interpretazione: validità, ripetibilità, scrutinio indipendente

ISO/IEC 27043

principi e processi dell'investigazione digitale end-to-end

Standard tecnici richiamati nel report

ITU-R BS.1770: loudness LUFS per normalizzazione percettiva.

ITU-T P.862.2: PESQ wideband per qualità percettiva stimata.

SHA-256: identificazione e controllo di integrità dei file.

Le norme ISO/IEC fungono da layer procedurale; il report implementa soprattutto il layer tecnico/sperimentale.

Nota: il report non dichiara una certificazione ISO; questa slide mappa la pipeline sugli standard forensi applicabili.

Metriche di qualità audio

SNR

rapporto segnale-rumore stimato in dB

più alto = segnale più pulito



Δ SNR

SNR enhanced - SNR originale

misura il guadagno netto



PESQ WB

qualità percettiva wideband

scala -0.5/4.5; proxy reference



STOI

intelligibilità oggettiva

0/1; vicino a 1 = alta intelligibilità



Attenzione metodologica: nel report PESQ usa l'originale degradato come riferimento proxy, non un parlato pulito ideale.

Metriche di trascrizione automatica

WER

Word Error Rate

$$(S + D + I) / N \text{ parole}$$

Misura errori su token parola; 0% è trascrizione perfetta.

CER

Character Error Rate

$$(S + D + I) / N \text{ caratteri}$$

Più granulare; spesso inferiore al WER perché il denominatore è più grande.

S

Sostituzioni

D

Cancellazioni


I

Inserzioni


Normalizzazione testuale nel confronto: minuscole, rimozione diacritici, punteggiatura e spazi multipli.

Risultati sperimentali: qualità audio

Delta SNR medio per condizione



PESQ e STOI medio



STOI RUMORE/SAT./TRAFFICO

≈0.98

alta intelligibilità

PESQ SATURAZIONE

4.23

miglior risultato

ΔSNR VOCI

+25.3

dB medio


PESQ VOCI

1.70


penalizzato dal proxy

Risultati ASR: Whisper e confronto Originale vs Enhanced

WER medio (%) - Originale vs Enhanced



CER medio (%) - Originale vs Enhanced



Miglioramento WER relativo: rumore -8%, saturazione -3%, traffico -8%; voci concorrenti +9% perché la separazione introduce artefatti ma isola la sorgente.

Caso critico: traffico urbano #3 raggiunge WER 57.8% e CER 36.0%, unico fallimento grave nel corpus.

Lettura forense dei risultati: benefici e limiti

Benefici

STOI molto alto
per 3 condizioni

Declicking efficace
sulla saturazione

Separazione utile
per sorgente target

ASR accelera
la documentazione

Limiti

SNR a cieco non sempre
coerente con percezione

possibili artefatti
in casi intermedi

PESQ proxy penalizza
la sorgente isolata

WER non nullo
e outlier severi

Contromisure

leggere metriche
in modo congiunto

controllo per file
non solo media

usare reference pulito
quando disponibile

validazione forense
human-in-the-loop

Conclusione interpretativa: l'enhancement è tecnicamente efficace, ma il valore forense nasce dalla combinazione tra miglioramento, audit trail e controllo umano.

Tre takeaway

1

Pipeline multi-stadio efficace

DFN, Wiener, declipping e SepFormer migliorano qualità e intelligibilità in scenari degradati.

2

Valutazione quantitativa necessaria

SNR, PESQ, STOI, WER, CER e decomposizione S/D/I permettono una lettura diagnostica.

3

Validazione umana non negoziabile

Whisper accelera la trascrizione ma l'esperto certifica contenuto, integrità e ammissibilità.

Roadmap

- validazione su corpus più ampio
- riferimento pulito per metriche intrusive
- benchmark con modelli ASR alternativi
- report automatico di audit e catena di custodia
- interfaccia per revisione human-in-the-loop




Output consigliato: audio enhanced + originale + log parametri + hash + trascrizione revisionata.

Conclusioni e Future Work

La pipeline multi-stadio basata su **DeepFilterNet** e **Whisper** offre un supporto senza precedenti all'analisi forense, ma con un vincolo non negoziabile:


Human-In-The-Loop

L'AI è un acceleratore, non un sostituto. La validazione finale del trascrivente forense certificato rimane l'unico criterio per l'ammissibilità probatoria.



Massimo Orazio Spata
massimo.spata@unict.it

Università di Catania
Dipartimento di Matematica e Informatica



04

Keystrokes classification problem



Un po' di
storia:
Agosto 2023...

#1 Trusted Cybersecurity News Platform

Followed by 4.50+ million [Twitter](#) [LinkedIn](#) [Facebook](#)

The Hacker News

Get the Free Newsletter

Home Data Breaches Cyber Attacks Vulnerabilities Webinars Store Contact

Prevent SaaS Data Breaches Before They Happen [START SECURING](#)

New 'Deep Learning Attack' Deciphers Laptop Keystrokes with 95% Accuracy

Aug 07, 2023 Newsroom Deep Learning / Endpoint Security



Actionable AWS Security Best Practices Cheat Sheet [View Now](#)

WIZ

2023 CISO Compensation

News ▸ [UK](#) ▸ [AI](#)

Protect against new AI attack vector using keyboard sounds to guess passwords over Zoom

AI acoustic analysis decodes 95% of Zoom keystrokes, a statistic that's ringing cybersecurity alarms.



Liam 'Akiba' Wright

Aug. 8, 2023 at 1:30 pm UTC

2 min read

Updated: August 8, 2023 at 10:40 am



Cover art/illustration via CryptoSlate

Il problema

- Creare un prototipo di app mobile per la registrazione dei tasti premuti su una tastiera fisica, attraverso una nuova pipeline addestrando un modello di Deep Learning su un Dataset creato appositamente offline per un modello di tastiera noto a priori.

IL PROBLEMA DEL KEYSTROKE DETECTION




Il keystroke detection consiste nell'individuare i singoli tasti premuti su una tastiera utilizzando solo il segnale audio captato da un microfono.

È un problema complesso per vari motivi.

1 ACQUISIZIONE DEL SEGNALE


Il microfono acquisisce un segnale che contiene i suoni dei tasti ma anche molti altri suoni presenti nell'ambiente (rumore di fondo).

■ Tasto 1 ■ Tasto 2 ■ Tasto 3 ■ Rumore di fondo



2 SPETTROGRAMMA

Nello spettrogramma, i colpi dei tasti sono eventi brevi e a banda larga, spesso mascherati dal rumore.



3 PRINCIPALI DIFFICOLTÀ



RUMORE DI FONDO

Il rumore ambientale può mascherare i suoni dei tasti, rendendo difficile la loro individuazione.



EVENTI MOLTO BREVI

I suoni dei tasti durano pochi millisecondi e possono sovrapporsi tra loro.



VARIABILITÀ

Lo stesso tasto può produrre suoni diversi in base alla forza, alla posizione e alla superficie d'appoggio.



DISTANZA E POSIZIONE

La distanza e la posizione del microfono rispetto alla tastiera influenzano fortemente il segnale.



SIMILARITÀ TRA TASTI

Suoni di tasti diversi possono essere molto simili, aumentando il rischio di errori.

4 OBIETTIVO



Rilevare con accuratezza il momento in cui ogni tasto viene premuto e, se possibile, identificare quale tasto è stato premuto.

APPLICAZIONI

Sicurezza informatica (eavesdropping), autenticazione biometrica, analisi del comportamento, accessibilità.




La soluzione proposta su piattaforma mobile

- Per risolvere il problema presentato, abbiamo dovuto innanzitutto affrontare alcune sfide chiave:
 - Tradurre il codice Python in Java per Android al fine di creare un'app eseguibile localmente sullo smartphone, oppure, in alternativa, ospitare gli script Python su un server remoto e caricare l'audio registrato sul server?
 - Abbiamo adottato una soluzione client-server con un'app mobile Android che registra l'audio sul client e lo carica sul server, e un modello pre-addestrato con tutti gli script Python ospitati su un server remoto.
 - Abbiamo creato uno script Python lato server per segmentare automaticamente l'audio registrato ed eseguire un rilevamento intelligente.
 - Abbiamo sviluppato un nuovo algoritmo dinamico basato sulle trasformate wavelet per eseguire un rilevamento intelligente dei clic.
 - Abbiamo estratto le caratteristiche dall'audio segmentato per classificare la pressione dei tasti in diverse condizioni: con rumore di fondo, a diverse velocità di digitazione, con diversa energia di digitazione, a diverse distanze e direzioni dello smartphone dalla tastiera.
 - Abbiamo creato 8 diversi set di esperimenti e dataset per esplorare e testare il modello addestrato in queste diverse condizioni.

Il primo prototipo di mobile app



Prior art




La crescente dipendenza dai sistemi digitali ha acuito le preoccupazioni relative alle vulnerabilità della sicurezza, portando all'esplorazione di nuovi vettori di attacco, come gli attacchi acustici basati sulla pressione dei tasti delle tastiere.



Questo lavoro approfondisce un approccio di apprendimento profondo per contrastare tali attacchi, che sfruttano le emissioni acustiche prodotte durante la digitazione per dedurre informazioni sensibili come i tasti premuti.



Nell'articolo "A Practical Deep Learning-Based Acoustic Side Channel Attack on Keyboards" [2], Gli autori hanno addestrato un modello di apprendimento profondo sui tasti premuti registrati da un telefono nelle vicinanze; il classificatore ha raggiunto un'accuratezza di validazione massima del 95%.




Nel nostro lavoro, partendo dallo stesso dataset utilizzato in [2], abbiamo ottenuto un'accuratezza di convalida di picco del 98,3% [33], che rappresenta la migliore prestazione effettivamente raggiunta per questo tipo di problemi.

[2] J. Harrison, E. Toreini and M. Mehrnezhad, "A Practical Deep Learning-Based Acoustic Side Channel Attack on Keyboards," in 2023 IEEE European Symposium on Security and Privacy Workshops (EuroS&PW), Delft, Netherlands, (2023) pp. 270-280.

[33] Spata, M.O., Ortis, A., Battiato, S., Russo, V.M. (2024). A New Deep Learning Pipeline for Acoustic Attack on Keyboards. In: Arai, K. (eds) Intelligent Systems and Applications. IntelliSys 2024. Lecture Notes in Networks and Systems, vol 1065. Springer, Cham. https://doi.org/10.1007/978-3-031-66329-1_26

Pipeline



La soluzione

Preprocessing of the audio dataset:

- Split every audio file in n audio files one for every keystroke, recognizing audio peaks
- Data augmentation of the splitted audio files in order to help the model generalize better
- Extract audio features through mfccs (mel frequency cepstral coefficients) technique (instead Toreini et al use Spectrum Images)
- Encode the features into the dataset

Load the dataset

Split dataset in training and validation

Build a Temporal Convolutional Network model

Hyperparameters tuning of the model parameters

Train and validation of the model


Plot all the metrics to analyze and validate results

Validate every possible audio class file extracting its mfcc features and detect its value through the prediction label achieved by the model

Plot all the metrics to analyze and validate results

Validate every possible audio class file extracting its mfcc features and detect its value through the prediction label achieved by the model

Preprocessing



Split every audio file in n audio files one for every keystroke, recognizing audio peaks



Data augmentation of the splitted audio files in order to help the model generalize better



Extract audio features through Mel Frequency Cepstral Coefficients



Encode the features into the dataset




Features

- Nei modelli di deep learning, le caratteristiche si riferiscono alle variabili di input o agli attributi che il modello utilizza per fare previsioni. Queste caratteristiche sono le informazioni grezze o le caratteristiche dei dati da cui il modello apprende individuando schemi e relazioni.
- La scelta e la qualità delle caratteristiche giocano un ruolo cruciale nelle prestazioni di un modello di deep learning.


Experimental Setup 1



Experimental desktop setup with a laptop MateBook at 17 cm




a




b

Risultati sperimentali: audio wave

- Audio registrato direttamente con uno smartphone (iPhone 13) su un Macbook Pro a una distanza di 17 cm.
- Audio registrato con uno smartphone (iPhone 13) tramite lo strumento di videoconferenza Zoom su un Macbook Pro a 17 cm.



a



b





Experimental results: the spectrogram

- Audio registrato direttamente con uno smartphone (iPhone 13) su un Macbook Pro a una distanza di 17 cm.
- Audio registrato con uno smartphone (iPhone 13) tramite lo strumento di videoconferenza Zoom su un Macbook Pro a 17 cm.

Risultati sperimentali sul dataset esistente

TABLE 2. EXPERIMENTAL RESULTS ABOUT CoAtNet AND THE IMPLEMENTED TCN

Model	Precision	Recall	F1-Score
CoAtNet [2]	0.960	0.950	0.950
TCN [1]	0.980	0.983	0.983



Risultati sperimentali di accuratezza a diverse distanze e direzioni

TABLE 4. OVERVIEW OF TCN MODEL PERFORMANCE ON VARIOUS DATASETS (ALL WITH 1-SECOND TYPING INTERVALS)


Distance (cm)	Peak accuracy (%)	Peak loss
17	99.44	0.0624
50	98.88	0.0923
100	97.02	0.1244
17 (dataset used in [2])	98.30	0.1943

TABLE 6. RESULTS OF THE INFERENCE TESTS COMPARED TO AUDIO DATASET FROM DIFFERENT DIRECTIONS.

Audio Direction	Peak Accuracy (%)
East	99.44
South	40.02
West	20.45
North	37.81

Seconda versione dell'app in modalità offline





05

Applicazioni avanzate: rilevamento e attribuzione di deepfake audio




Feature classification

Possiamo classificare le caratteristiche audio in tre livelli:

- descrittori di basso livello (forma d'onda grezza, misure di energia),
- caratteristiche di livello intermedio (MFCC, descrittori spettrali, ecc.),
- embedding di alto livello appresi ed estratti da reti neurali.

Ogni livello cattura diversi aspetti del segnale ed è adatto a compiti differenti.




Audio Deepfake

I deepfake audio sono registrazioni vocali sintetiche generate da modelli di intelligenza artificiale come la sintesi vocale (Text-to-Speech) o la conversione vocale (Voice Conversion) in grado di imitare la voce umana con elevata fedeltà, inclusi tono, prosodia ed emozioni.

Applicazioni utili: strumenti di accessibilità, assistenti virtuali, intrattenimento, ecc.

Rischi: impersonificazione, frode, disinformazione, erosione della fiducia nei media.




Key challenges in ADD

Audio reale: insieme aperto → infinita varietà di altoparlanti, canali e condizioni di rumore.

Audio simulato: insieme chiuso → numero finito di generatori (sistemi TTS/VC).

I modelli spesso offrono buone prestazioni all'interno del dominio di applicazione, ma scarse prestazioni in domini diversi.



Towards detection: audio attribution

Esistono numerosi studi all'avanguardia sul rilevamento di deepfake audio.

- A questo punto, è possibile risalire all'origine di un audio?
- È possibile definire quale modello lo ha generato?

Solo pochi lavori cercano di rispondere a queste domande, ma:

- Vengono addestrati e testati su dataset non disponibili pubblicamente o non ampiamente utilizzati dai ricercatori.
- Non è possibile riprodurli e migliorarli.

Proprio come per l'ADHD, i modelli sono efficaci nel dominio di applicazione, ma deboli al di fuori di esso. Non è possibile applicarli a scenari reali.



Due articoli da IPLab

From detection

to attribution



End-to-end Audio Deepfake Detection from RAW Waveforms: a RawNet-Based Approach with Cross-Dataset Evaluation

Andrea Di Pierno¹, Luca Guarnera¹, Dario Allegri², Sebastiano Buitano²

¹IMT School of Advanced Studies Lucca, Lucca, Italy

²Department of Mathematics and Computer Science, University of Catania, Catania, Italy

andrea.diperno@phd.unict.it, luca.guarnera, dario.allegri, sebastiano.buitano@unict.it

Abstract—Audio deepfakes represent a growing threat to digital security and trust, lowering advanced generative models to produce content which closely mimics real human voices. Detecting such manipulations is especially challenging under open-world conditions, where spoofing methods are constantly evolving. In this paper, we propose an end-to-end deep learning framework for audio deepfake detection that operates directly on raw waveforms. Our model, RawNet-Lite, is a lightweight convolutional-recurrent architecture designed to capture both spectral and temporal features without handcrafted preprocessing. To enhance robustness, we introduce a training strategy that combines data from multiple domains and adapts Focal Loss to emphasize difficult or ambiguous samples. We further demonstrate that incorporating codebook manipulation and applying waveform-level audio representations (e.g., pitch, timing, onset, and time stretching) leads to significant generalization improvements under realistic acoustic conditions. The proposed model achieves over 90% F1 and 8.25% EER on in-domain data (Fake0Voice), and up to 83.4% F1 and 34.4% EER on a challenging out-of-distribution test set (ANVoice2021 + CodeFakes). These findings highlight the importance of diverse training data, tailored objective functions, and audio representations in building robust and generalizable audio forgery detectors. Code and pretrained models are available at <https://github.com/ai-unict/deepfakes/raw-net-lite>.

Index Terms—audio deepfake detection, synthetic speech recognition, raw audio classification, end-to-end learning, convolutional neural networks, RawNet, digital media forensics. This study has been partially supported by SIRCS (PERCROM4) under the MUR National Recovery and Resilience Plan funded by the European Union - NextGenerationEU.

1. INTRODUCTION

Deepfake technologies have rapidly evolved in recent years, enabling the generation of synthetic content that is visually or audibly indistinguishable from real data. While most attention has focused on visual deepfakes—such as face-swapped videos or manipulated facial expressions [1]–[3]—advances in generative modeling have also enabled highly convincing audio deepfakes [4]. These include text-to-speech (TTS) and voice conversion (VC) systems capable of replicating a speaker's voice with remarkable fidelity, raising growing concerns over impersonation, fraud, and misinformation in domains such as finance, politics, and social media.

While audio synthesis brings clear benefits for accessibility, entertainment, and human-computer interaction, it also introduces serious risks to security and public trust. In particular, the rise of audio deepfakes contributes to a form of impostor bias, where individuals increasingly question the authenticity of audio content, undermining trust in legitimate recordings across domains such as journalism, legal evidence, and personal communication [5]. Recent work has shown that deepfakes are especially dangerous in subtle scenarios where background noise or speech hesitations may aid deception [6].

As a result, robust audio deepfake detection has become a pressing need. Researchers have explored diverse strategies, including forensic analysis [7], chatter moderation [8], and the detection of synthetic media more broadly [9]. Other works have critically examined the state of voice spoofing research [10], highlighting open challenges in generalization and dataset bias. Detecting audio deepfakes remains challenging. Many systems rely on handcrafted features (e.g., MFCCs, QCCFs) or spectrogram-based representations, which may fail to capture fine-grained temporal cues or generalize to unseen manipulations. Moreover, the detection task exhibits a core asymmetry: real audio spans a vast and diverse open domain (speakers, microphones, environments), whereas fake audio is generated by a finite, albeit expanding, set of models. This leads to frequent overfitting on known attacks and poor generalization to new ones.

In this work, we propose *RawNet-Lite*, a lightweight end-to-end architecture for audio deepfake detection, trained directly on raw waveforms. Unlike many prior approaches, *RawNet-Lite* does not rely on spectrogram transformation or large pretrained backbones. To improve generalization, we combine three strategies: (i) domain-mix training across multiple datasets (Fake0Voice, ANVoice2021, and CodeFakes); (ii) waveform-level data augmentation (pitch shift, noise injection, and time stretching); and (iii) Focal Loss to emphasize hard or ambiguous samples during training.

While the generalization gap in audio deepfake detection is well known, our contribution lies in systematically exploring lightweight, reproducible solutions within a unified end-to-end framework. Rather than proposing entirely new components, we demonstrate how domain-mix training, Focal Loss, and waveform-level augmentation can be effectively combined

Towards Reliable Audio Deepfake Attribution and Model Recognition: A Multi-Level Autoencoder-Based Framework

Andrea Di Pierno¹, Luca Guarnera¹, Dario Allegri², Sebastiano Buitano²

¹IMT School of Advanced Studies Lucca, Lucca, Italy

andrea.diperno@phd.unict.it

Dario Allegri²

University of Catania

Department of Mathematics and Computer Science
Catania, Sicily, Italy
dario.allegri@unict.it

Luca Guarnera¹

University of Catania

Department of Mathematics and Computer Science
Catania, Sicily, Italy
luca.guarnera@phd.unict.it

Sebastiano Buitano²

University of Catania

Department of Mathematics and Computer Science
Catania, Sicily, Italy
sebastiano.buitano@unict.it

Abstract

The proliferation of audio deepfakes poses a growing threat to trust in digital communications. While detection methods have advanced, attributing audio deepfakes to their source models remains an underexplored yet critical challenge. In this paper, we introduce *LAIO* (Layered Architecture for Voice Attribution), a hierarchical framework for audio deepfake detection and model recognition that leverages iterative enhanced latent representations extracted by a convolutional autoencoder trained solely on fake audio. Two specialized classifiers operate on these features: *Audio Deepfake Attribution (ADA)*, which identifies the generation technology, and *Audio Deepfake Model Recognition (ADM)*, which recognizes the specific generation model instance. To improve robustness under open-world conditions, we incorporate confidence-based rejection thresholds. Experiments on ANVoice2021, CodeFakes, and CodeFake show strong performance: the ADA classifier achieves F1 scores over 90% across all datasets, and the ADM module reaches 96.3% mean F1 across all classes. Additional tests on unseen attack-hops on ANVoice2021 A and error propagation analysis confirm LAIO's robustness and reliability. The framework advances the field by introducing a supervised approach to deepfake attribution and model recognition under open-set conditions, validated on public benchmarks and accompanied by publicly released models and code. Models and code are available at <https://github.com/adipio/9LAIO-framework>.

CS2 Categories

• **Applied computing** → Computer forensics • **Security and privacy** → Domain specific security and privacy architectures • **Computing methodologies** → Neural networks.



This work is licensed under a Creative Commons Attribution 4.0 International License. For more information, see <http://creativecommons.org/licenses/by/4.0/>.
PDF 25, 246kb, 1mbd
arXiv:2507.16673v1 [cs.LG] 10 Jul 2025
DOI: 10.26434/chemrxiv-2025-16673
https://doi.org/10.26434/chemrxiv-2025-16673

Keywords

Audio deepfakes, Deepfake attribution, Model recognition, Open-set recognition, Neural networks, Autoencoders, Attention mechanisms, Digital forensics, Synthetic speech, Deepfake detection

ACM Reference Format

Andrea Di Pierno, Luca Guarnera, Dario Allegri, and Sebastiano Buitano. 2025. Towards Reliable Audio Deepfake Attribution and Model Recognition: A Multi-Level Autoencoder-Based Framework. In *Proceedings of the 1st Deepfake Forensics Workshop: Detection, Attribution, Recognition, and Automated Analysis by the Use of AI Generated Media (DF25)*, October 27–28, 2025, Seattle, WA, USA, New York, NY, USA, 9 pages. <https://doi.org/10.1145/3764252.3764258>

1 Introduction

The rise of synthetic audio generation technologies, particularly those based on deep learning, has led to the widespread emergence of deepfakes: manipulated audio, video, or images that convincingly imitate real individuals [1, 2]. Among these, audio deepfakes have attracted increasing attention due to their potential to impersonate voices in high-stakes contexts such as secure authentication, political discourse, and disinformation campaigns. For instance, fraudulent voice of President Biden was used in a robo-call to mislead voters ahead of the New Hampshire primary¹. While audio synthesis offers valuable benefits in fields such as accessibility, entertainment, and human-computer interaction, it also introduces serious risks to security and public trust. In particular, the proliferation of audio deepfakes fosters a growing form of impostor bias [3], in which the authenticity of genuine audio is increasingly questioned. This erosion of trust impacts critical domains including journalism, legal evidence, and personal communication. While recent studies have begun to explore audio deepfake attribution [2, 3, 4, 5, 6], they often tackle the problem from alternative perspectives, such as speaker identification, pipeline inference,

¹<https://www.bbc.com/news/health-66966666> (2021-01-03) (page last viewed: 2025-07-16).
²<https://www.bbc.com/news/health-66966666> (2021-01-03) (page last viewed: 2025-07-16).
³<https://www.bbc.com/news/health-66966666> (2021-01-03) (page last viewed: 2025-07-16).

- “End-to-end Audio Deepfake Detection from RAW Waveforms: a RawNet-Based Approach with Cross-Dataset Evaluation”. IJCNN 2025
- “Towards Reliable Audio Deepfake Attribution and Model Recognition: A Multi-Level Autoencoder-Based Framework”. ACM Multimedia 2025

End-to-end detection: RawNetLite

All'avanguardia nella ricerca sul rilevamento di deepfake audio, sono in corso numerosi studi.

A questo punto, è possibile risalire all'origine di un audio?


È possibile definire quale modello lo ha generato?

La nostra rete neurale è stata progettata specificamente per dispositivi di uso quotidiano, come gli smartphone, che dispongono di risorse limitate.

Si tratta di una versione leggera della rete neurale RawNet2, che rappresenta un compromesso tra risorse richieste e prestazioni.

L'input è un audio grezzo campionato a 16 kHz e tagliato a 3 secondi.


L'output è un'etichetta che indica se il suono è "reale" o "deepfake".



Accuracy VS. simplicity

RawNetLite apprende dalle forme d'onda audio grezze, evitando caratteristiche create manualmente come MFCC o CQCC. Invece di affidarsi a modelli pre-addestrati di grandi dimensioni, utilizza un'architettura personalizzata e leggera.

- Perché non vengono utilizzati spettrogrammi? L'audio grezzo preserva i dettagli temporali essenziali per il rilevamento delle falsificazioni.
- Cosa apprende il modello? L'estrazione delle caratteristiche viene eseguita direttamente tramite layer convoluzionali, seguiti da GRU per catturare le dipendenze a lungo raggio.
- Pre-elaborazione minima: solo ricampionamento a 16 kHz, normalizzazione e troncamento a 3 secondi.






LAVA: Layered Architecture for Voice Attribution


Con questo lavoro, abbiamo introdotto un framework di attribuzione multilivello basato su autoencoder, con due livelli di attribuzione.

L'obiettivo finale è ottenere un sistema di attribuzione granulare, robusto a campioni fuori dominio e modulare.

La modularità è la chiave di questo lavoro: possiamo aggiornare ciascun livello separatamente e stimolare i ricercatori a contribuire a questo nuovo campo producendo modelli sempre migliori.



The LAVA framework




The base model

Il modello di base è un autoencoder addestrato esclusivamente su parlato simulato per apprendere gli artefatti di generazione.

L'encoder estrae rappresentazioni latenti dall'audio manipolato. Al termine dell'addestramento, il decoder viene scartato e l'encoder viene utilizzato come estrattore di caratteristiche.

Questo processo garantisce che le caratteristiche siano specializzate per l'attribuzione.



Multi-level attribution

Livello 1 – Attribuzione Deepfake Audio (ADA)


- Classifica l'audio in base al dataset/tecnologia

Livello 2 – Riconoscimento del Modello Deepfake Audio (ADMR)

- Classifica l'audio in base al codec/modello

La soglia di rifiuto garantisce robustezza ai codec non visti:

- Se la confidenza è inferiore alla soglia → Sconosciuto



Results

With the same preprocessing of the previous work (16KHz, 3sec.) we obtain very high accuracy scores, both over 96%.

Table 5: Audio Deepfake Attribution (ADA) results

Dataset	Precision	Recall	F1-Score
CodecFake	0.9749	0.9568	0.9658
ASVspoof2021	0.9402	0.9720	0.9558
FakeOrReal	0.9724	0.9576	0.9649
Accuracy		0.9621	
Macro Avg	0.9625	0.9621	0.9622
Weighted Avg	0.9625	0.9621	0.9622

Table 6: Audio Deepfake Model Recognition (ADMR) results

Class	Precision	Recall	F1-Score
F01	0.9975	0.9980	0.9978
F02	0.9016	0.9325	0.9168
F03	0.9921	0.9959	0.9940
F04	0.9789	0.9880	0.9835
F05	0.9778	0.9741	0.9760
F06	0.9319	0.8907	0.9108
Accuracy		0.9632	
Macro Avg	0.9633	0.9632	0.9631
Weighted Avg	0.9633	0.9632	0.9631